

Análisis de series temporales de infraestructura productiva y de telemetría de vuelo

Trabajo Práctico N.º 1

Análisis de Series Temporales
Maestría en Ciencia de Datos
Universidad Austral

Docentes

Rodrigo Del Rosso
Sebastián Calcagno
Brian Drago

Integrantes

Carlos Aular
Juan Manuel Pedrozo

Agosto de 2026

Resumen ejecutivo

El presente trabajo analiza tres series temporales mediante modelos de la familia ARIMA y un modelo de vectores autorregresivos. Dos de las series provienen de la infraestructura productiva de una plataforma comercial y registran, con frecuencia horaria, el volumen de solicitudes atendidas por un balanceador de carga y por una interfaz de punto de venta. La tercera proviene de la telemetría de vuelo de una aeronave no tripulada de ala fija y registra su altitud con frecuencia de un segundo.

Las dos series de tráfico exhiben estacionalidad diaria con período de veinticuatro horas y quedan representadas por modelos SARIMA. La serie de altitud resulta un proceso integrado sin componente estacional y queda representada por un modelo ARIMA(1, 1, 3), cuyos parámetros son significativos tanto individual como conjuntamente, y cuyos residuos no se distinguen del ruido blanco.

El modelo de vectores autorregresivos se construye sobre las dos series de tráfico, únicas que comparten calendario. La especificación adoptada emplea dos rezagos, respaldada por los criterios bayesiano y de Hannan-Quinn. La prueba de causalidad de Granger arroja un resultado unidireccional: los rezagos de la serie de punto de venta contribuyen a explicar la serie del balanceador, mientras que la relación inversa no alcanza significatividad.

Los principales límites del trabajo son el tamaño muestral de cada serie, el solapamiento de apenas trece días entre las dos series de tráfico, y la imposibilidad de incorporar la serie de altitud al modelo multivariado por corresponder a un calendario disjunto.

Índice

Resumen ejecutivo	1
Introducción	6
Planteo del problema	6
Origen de los datos	6
Series de infraestructura productiva	6
Serie de telemetría de vuelo	6
Organización del informe	7
Marco teórico	8
Estacionariedad	8
Procesos autorregresivos y de medias móviles	8
Modelos ARIMA y SARIMA	9
Modelos de vectores autorregresivos	9
Contrastes de hipótesis empleados	10
Criterios de selección y métricas de error	11
Herramientas de cómputo	11
Análisis de resultados	11
Elección de las series y contexto (punto 1)	11
Series originales y necesidad de diferenciar (punto 2)	12
Series de tráfico	12
Serie de altitud	14
Funciones de autocovarianza, autocorrelación y autocorrelación parcial (punto 3)	14
Pruebas de raíces unitarias (punto 4)	16
Estimación y selección de modelos (punto 5)	17
Series de tráfico	17
Serie de altitud	18
Desempeño y comparación entre modelos (puntos 6 y 7)	19
Diagnóstico de residuos (punto 8)	20
Series de tráfico	20
Serie de altitud	20
Pronósticos (punto 9)	22
Modelo de vectores autorregresivos (punto 10)	23
Alcance y restricción de calendario	23
Selección del orden de rezagos	23
Sobre la medición del error	24
Impulso-respuesta y causalidad (punto 11)	25
Estacionalidad y representación mediante SARIMA (punto 12)	26

Conclusiones	27
Hallazgos principales	27
Dos lecciones metodológicas	27
Límites del trabajo	28
Líneas de trabajo futuro	28
Declaración de uso de IA generativa	29
Referencias bibliográficas	30

Índice de figuras

1.	Series de tráfico en niveles, con frecuencia horaria	12
2.	Perfil medio por hora del día. La banda representa el rango intercuartílico; las líneas verticales señalan el máximo y el mínimo	13
3.	Solicitudes medias según día de la semana y hora del día	13
4.	Efecto de la diferencia estacional y de su combinación con la diferencia regular . . .	14
5.	Altitud relativa del vuelo en niveles y en primera diferencia	15
6.	Funciones FAS, FAC y FACP de la serie del balanceador de carga	15
7.	Funciones FAS, FAC y FACP de la serie de punto de venta	15
8.	Funciones FAS, FAC y FACP de la altitud en niveles	16
9.	Funciones FAS, FAC y FACP de la altitud tras una diferencia regular	16
10.	Diagnóstico de residuos del modelo de la serie del balanceador de carga	21
11.	Diagnóstico de residuos del modelo de la serie de punto de venta	21
12.	Diagnóstico de residuos del modelo de la serie de altitud	21
13.	Pronóstico a 48 horas de la serie del balanceador de carga	22
14.	Pronóstico a 48 horas de la serie de punto de venta	22
15.	Pronóstico a 15 segundos de la serie de altitud, con intervalo de confianza	23
16.	Pronóstico del modelo multivariado a 48 horas, expresado en la escala original	25
17.	Funciones impulso-respuesta ortogonalizadas del modelo de dos rezagos	26
A1.	Serie horaria del balanceador de carga, análisis exploratorio	31
A2.	Serie horaria de punto de venta, análisis exploratorio	32
A3.	Agregación diaria de la serie del balanceador de carga	32
A4.	Agregación diaria de la serie de punto de venta	32
A5.	Patrón por día de la semana, serie del balanceador de carga	33
A6.	Patrón por día de la semana, serie de punto de venta	33
A7.	Media y desvío estándar móviles, serie del balanceador de carga	34
A8.	Media y desvío estándar móviles, serie de punto de venta	34
A9.	Descomposición estacional de la serie del balanceador de carga	35
A10.	Descomposición estacional de la serie de punto de venta	35
A11.	Ajuste sobre el conjunto de prueba, serie del balanceador de carga	36
A12.	Ajuste sobre el conjunto de prueba, serie de punto de venta	36

Índice de tablas

1.	Contrastes empleados, con sus hipótesis y regla de decisión	10
2.	Series analizadas	11
3.	Contrastes de raíces unitarias sobre las series de tráfico	17
4.	Comparación de modelos SARIMA estimados	18
5.	Parámetros del modelo ARIMA(1,1,3) de la serie de altitud	19
6.	Desempeño de los modelos seleccionados sobre el conjunto de prueba	19

7.	Prueba de Ljung-Box sobre los residuos de los modelos SARIMA	20
8.	Orden de rezagos sugerido por cada criterio	24
9.	Comparación de especificaciones del modelo multivariado a 48 horas	24
10.	Contrastes de causalidad de Granger sobre el modelo adoptado	25

Introducción

Planteo del problema

El análisis de series temporales persigue dos objetivos que conviene distinguir. El primero es descriptivo: comprender qué estructura gobierna la evolución de una magnitud a lo largo del tiempo, si esa estructura es estable y qué componentes la integran. El segundo es predictivo: anticipar valores futuros con una medida explícita de la incertidumbre asociada. Este trabajo aborda ambos sobre tres series de naturaleza distinta.

La elección de series heterogéneas responde a un propósito deliberado. Un conjunto de datos que exhibe estacionalidad marcada y otro que carece por completo de ella exigen caminos de identificación diferentes, y contrastarlos ilumina mejor el método que repetir tres veces el mismo procedimiento sobre series equivalentes.

Origen de los datos

Series de infraestructura productiva

Las dos primeras series provienen de la telemetría operativa de una plataforma comercial en producción y fueron registradas durante 2026.

La primera contabiliza las solicitudes atendidas por hora por el balanceador de carga que recibe todo el tráfico entrante de la plataforma. Abarca las 744 horas del mes de julio de 2026, expresadas en tiempo universal coordinado, sin interrupciones ni huecos. El volumen promedio ronda los 2,1 millones de solicitudes por hora (BodegaAI, 2026a).

La segunda contabiliza las solicitudes por hora dirigidas a cada destino de la interfaz de punto de venta. Abarca 720 horas comprendidas entre el 18 de julio y el 17 de agosto de 2026, también sin faltantes, con un volumen promedio cercano a las 830.000 solicitudes por destino y por hora (BodegaAI, 2026b).

Ambas fueron reindexadas sobre una grilla horaria completa antes del análisis. El procedimiento cumple una función diagnóstica además de correctiva: revela cualquier hueco temporal que de otro modo pasaría inadvertido, puesto que los modelos suponen observaciones equiespaciadas y una interrupción no declarada distorsionaría las funciones de autocorrelación.

Serie de telemetría de vuelo

La tercera serie procede del acervo ALFA, un conjunto de registros de telemetría de una aeronave no tripulada de ala fija recopilado por el Instituto de Robótica de la Universidad Carnegie Mellon (Keipour et al., 2020). El protocolo de comunicación transmite el estado de la aeronave a la estación de tierra y almacena cada mensaje precedido de una marca temporal con resolución de microsegundos.

El acervo fue construido con una finalidad específica: proveer datos para la investigación en **detección de fallas y anomalías** en vehículos aéreos no tripulados. Comprende cuarenta y siete vuelos, veintitrés de los cuales presentan falla súbita de motor y veinticuatro corresponden a fallas de

superficies de control (Keipour et al., 2021). Esa finalidad refuerza el interés analítico de la altitud: su predicción de corto plazo es justamente el insumo sobre el cual un sistema de supervisión detecta desviaciones respecto del comportamiento esperado.

Los registros de telemetría en bruto, a diferencia de las secuencias procesadas del acervo, no incorporan etiquetas de falla, de modo que no cabe afirmar a partir de ellos si un vuelo determinado corresponde a un escenario nominal o a uno con falla inyectada. El vuelo analizado en este trabajo no exhibe, en todo caso, indicios de falla de motor: el acelerador permanece activo durante todo el tramo, con una media que oscila entre el veinte y el cuarenta y cinco por ciento según el minuto, y la velocidad aerodinámica media de 16,6 metros por segundo se mantiene próxima a la velocidad de crucero de quince metros por segundo que fijan los parámetros de configuración. La colección disponible comprende cuarenta y un registros repartidos en cinco jornadas de 2018.

La variable analizada es la altitud relativa al punto de despegue, transmitida en milímetros y convertida a metros. Se prefirió esta magnitud sobre la altitud respecto del nivel del mar por tres razones: se lee directamente como altura de vuelo, se muestrea a mayor frecuencia, y permite detectar el contacto con el suelo sin conocer la elevación del campo.

La construcción de la serie exigió dos decisiones. La primera consistió en aislar el tramo efectivamente en vuelo, puesto que la mayor parte de cada registro corresponde a la aeronave detenida en tierra, donde la altitud transmitida es únicamente deriva del barómetro. En uno de los vuelos examinados, el registro se extiende durante 2.880 segundos mientras la mediana de velocidad respecto del suelo alcanza apenas 0,16 metros por segundo. Modelar ese tramo equivaldría a modelar ruido de sensor. Se conservó, en consecuencia, el bloque contiguo más extenso con altitud superior a tres metros.

La segunda decisión fue la frecuencia de análisis. La serie se llevó a una grilla regular de un segundo. Dado que la frecuencia nativa ronda los 4,15 hertz, la operación es un submuestreo y no introduce puntos interpolados. Una grilla más fina habría duplicado el número de observaciones al costo de interpolar, y esos puntos artificiales inflarían la autocorrelación de rezago corto, que es precisamente la magnitud sobre la cual se apoya la identificación del modelo.

La serie resultante comprende 457 observaciones que recorren un perfil de vuelo completo, desde el despegue hasta el descenso, con altitudes entre 4,9 y 82,8 metros.

Organización del informe

El apartado siguiente expone el marco teórico. El posterior desarrolla el análisis, organizado según los doce puntos que estructuran el trabajo. Las conclusiones sintetizan los hallazgos y delimitan su alcance. Los apéndices reúnen el material gráfico complementario y las rutinas de cómputo extensas.

Marco teórico

Estacionariedad

Un proceso estocástico $\{y_t\}$ es **estacionario en sentido débil** cuando cumple tres condiciones: su esperanza es constante, $E[y_t] = \mu$ para todo t ; su varianza es finita y constante, $\text{Var}(y_t) = \sigma^2$; y su autocovarianza entre dos instantes depende únicamente de la distancia que los separa,

$$\gamma_k = \text{Cov}(y_t, y_{t-k}), \quad (1)$$

sin depender de t (Box et al., 2015).

La exigencia no es formal. Los modelos ARMA estiman un número fijo de parámetros a partir de una única realización del proceso, y esa estimación sólo tiene sentido si las propiedades del proceso permanecen invariantes a lo largo de la muestra. Cuando la media se desplaza, el promedio muestral no estima ningún parámetro poblacional, y las regresiones entre series no estacionarias pueden arrojar asociaciones elevadas carentes de significado, fenómeno conocido como regresión espuria (Box et al., 2015).

La **función de autocorrelación** normaliza la autocovarianza,

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \quad (2)$$

y la **función de autocorrelación parcial** mide la correlación entre y_t e y_{t-k} una vez descontado el efecto de los rezagos intermedios. El comportamiento conjunto de ambas es la herramienta primaria de identificación.

Procesos autorregresivos y de medias móviles

Un proceso **autorregresivo de orden p** , denotado $\text{AR}(p)$, expresa el valor corriente como combinación lineal de sus propios rezagos más una perturbación:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t, \quad (3)$$

donde ε_t es ruido blanco de media nula y varianza σ^2 . Su autocorrelación decae de forma exponencial o sinusoidal, mientras que la parcial se anula a partir del rezago p .

Un proceso de **medias móviles de orden q** , $\text{MA}(q)$, expresa el valor corriente como combinación de perturbaciones presentes y pasadas:

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}. \quad (4)$$

El comportamiento es el inverso: la autocorrelación se anula a partir del rezago q y la parcial decae con lentitud.

El proceso **ARMA**(p, q) combina ambos. Con el operador de rezago B , definido por $By_t = y_{t-1}$,

se escribe de forma compacta:

$$\phi(B) y_t = \theta(B) \varepsilon_t, \quad (5)$$

donde $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ y $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$.

Modelos ARIMA y SARIMA

Cuando la serie no es estacionaria en niveles pero sí lo es tras diferenciar, el modelo incorpora un operador de diferencia $\nabla = 1 - B$. El modelo **ARIMA**(p, d, q) se escribe

$$\phi(B) (1 - B)^d y_t = \theta(B) \varepsilon_t, \quad (6)$$

donde d es el número de diferencias regulares necesarias. Corresponde emplearlo cuando la serie presenta tendencia o deriva pero carece de ciclo repetitivo.

Cuando además existe un patrón que se repite cada s períodos, el modelo **SARIMA**(p, d, q) $\times$ (P, D, Q) $_s$ agrega polinomios estacionales y una diferencia estacional $\nabla_s = 1 - B^s$:

$$\Phi(B^s) \phi(B) (1 - B)^d (1 - B^s)^D y_t = \Theta(B^s) \theta(B) \varepsilon_t. \quad (7)$$

El período s se fija según la periodicidad natural del fenómeno: veinticuatro para datos horarios con ciclo diario, siete para datos diarios con ciclo semanal (Hyndman & Athanasopoulos, 2021).

Modelos de vectores autorregresivos

Cuando varias series se determinan entre sí, el modelo **VAR**(p) trata a todas como endógenas y regresa cada una sobre los rezagos de todas (Sims, 1980). Para un vector $\mathbf{y}_t$ de dimensión K :

$$\mathbf{y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{y}_{t-1} + \dots + \mathbf{A}_p \mathbf{y}_{t-p} + \boldsymbol{\varepsilon}_t, \quad (8)$$

donde cada $\mathbf{A}_i$ es una matriz $K \times K$. El número total de parámetros asciende a $K(Kp + 1)$, y crece con el cuadrado de K y de forma lineal en p ; de ahí que la parsimonia pese más que en el caso univariado (Sims, 1980).

El modelo exige que todas las series estén definidas sobre el mismo calendario y sean estacionarias. La **función impulso-respuesta** describe la trayectoria de cada variable ante una perturbación unitaria en otra, y permite leer la dinámica del sistema más allá de los coeficientes individuales.

La **causalidad de Granger** contrasta si los rezagos de una variable mejoran la predicción de otra, más allá de lo que aportan los rezagos propios de esta última (Granger, 1969). La hipótesis nula sostiene que los coeficientes asociados a los rezagos de la variable candidata son conjuntamente nulos. El rechazo indica precedencia temporal con contenido predictivo, no causalidad en sentido estructural.

Contrastes de hipótesis empleados

La Tabla 1 resume los contrastes aplicados a lo largo del trabajo, con sus hipótesis y la regla de decisión correspondiente.

Tabla 1

Contrastes empleados, con sus hipótesis y regla de decisión

Contraste		Hipótesis nula	Hipótesis alternativa	Decisión al 5 %
Dickey-Fuller aumentada	au-	Existe una raíz unitaria; la serie no es estacionaria	La serie es estacionaria	Se rechaza si $p < 0,05$
KPSS		La serie es estacionaria en torno a un nivel o tendencia	Existe una raíz unitaria	Se rechaza si $p < 0,05$
Ljung-Box		Las autocorrelaciones hasta el rezago m son conjuntamente nulas	Existe autocorrelación	Se rechaza si $p < 0,05$
Jarque-Bera		Los residuos siguen una distribución normal	No siguen una distribución normal	Se rechaza si $p < 0,05$
Razón de verosimilitud		Los parámetros restringidos son conjuntamente nulos	Al menos uno es no nulo	Se rechaza si $p < 0,05$
Causalidad de Granger	de	Los rezagos de la variable candidata son conjuntamente nulos	Al menos uno es no nulo	Se rechaza si $p < 0,05$

Las pruebas de Dickey-Fuller aumentada (Dickey & Fuller, 1979) y KPSS (Kwiatkowski et al., 1992) plantean hipótesis nulas recíprocas. Esa reciprocidad justifica su aplicación conjunta: cuando ambas coinciden, la conclusión es sólida; cuando discrepan, la evidencia muestral no basta para pronunciarse con firmeza y la decisión debe apoyarse en elementos adicionales.

El estadístico de Ljung-Box (Ljung & Box, 1978) se define como

$$Q = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k}, \quad (9)$$

y se distribuye asintóticamente como una chi-cuadrado. Aplicado a los residuos de un modelo ajustado, es el contraste central del diagnóstico: si los residuos conservan autocorrelación, el modelo dejó estructura sin explicar.

El contraste de razón de verosimilitud compara un modelo ajustado contra una versión restringida mediante

$$LR = 2 (\ell_{\text{completo}} - \ell_{\text{restringido}}), \quad (10)$$

que se distribuye como una chi-cuadrado con tantos grados de libertad como restricciones impuestas. De ahí se obtiene la significatividad conjunta de los parámetros.

Criterios de selección y métricas de error

Los criterios de información penalizan la verosimilitud según el número de parámetros k sobre n observaciones:

$$\text{AIC} = -2\ell + 2k, \quad (11)$$

$$\text{BIC} = -2\ell + k \ln n, \quad (12)$$

$$\text{HQIC} = -2\ell + 2k \ln(\ln n). \quad (13)$$

El criterio de Akaike (Akaike, 1974) penaliza con menor severidad y tiende a seleccionar modelos más amplios; el bayesiano (Schwarz, 1978) impone una penalización creciente con el tamaño muestral y favorece la parsimonia; el de Hannan-Quinn (Hannan & Quinn, 1979) ocupa una posición intermedia. Si discrepan entre sí, el desempeño fuera de muestra rompe el empate.

Las métricas de error empleadas son el error absoluto medio, la raíz del error cuadrático medio y el error porcentual absoluto medio:

$$\text{MAE} = \frac{1}{h} \sum |e_t|, \quad \text{RMSE} = \sqrt{\frac{1}{h} \sum e_t^2}, \quad \text{MAPE} = \frac{100}{h} \sum \left| \frac{e_t}{y_t} \right|. \quad (14)$$

La última merece una advertencia. Al dividir por el valor observado, el error porcentual se vuelve inestable cuando el denominador se aproxima a cero, y pierde sentido sobre series que oscilan alrededor del origen (Hyndman & Koehler, 2006). Su empleo exige, por lo tanto, que la serie se encuentre expresada en una escala estable y alejada de cero.

Herramientas de cómputo

La estimación se realizó con la biblioteca *statsmodels* del lenguaje Python (Seabold & Perktold, 2010), que implementa los modelos SARIMAX y VAR mediante representación en espacio de estados y estimación por máxima verosimilitud.

Análisis de resultados

Elección de las series y contexto (punto 1)

Las tres series analizadas y sus características básicas se resumen en la Tabla 2. Los motivos de su elección y el origen de cada una se expusieron en la introducción.

Tabla 2

Series analizadas

Serie	Obs.	Frecuencia	Mínimo	Media	Máximo
Balanceador de carga	744	horaria	883.045	2.114.963	2.536.631
Punto de venta	720	horaria	318.308	829.950	924.147
Altitud de vuelo (m)	457	1 Hz	4,9	46,9	82,8

El fragmento siguiente resume la carga de las series horarias. La reindexación sobre una grilla completa cumple una función diagnóstica: revela huecos temporales que de otro modo pasarían inadvertidos y que distorsionarían las funciones de autocorrelación.

```
serie = df.set_index("period_start_utc")[columna].astype(float)
indice = pd.date_range(serie.index.min(), serie.index.max(), freq="h", tz="UTC")
serie = serie.reindex(indice).interpolate("time")
```

Código 1: Carga y reindexación sobre grilla horaria completa

En el caso de la telemetría de vuelo, la construcción exige además aislar el tramo en vuelo. El fragmento siguiente extrae la altitud del registro binario y descarta los tramos en tierra.

```
while (mensaje := conexion.recv_match(type="GLOBAL_POSITION_INT")) is not None:
    registros.append((mensaje._timestamp, mensaje.relative_alt / 1000.0))
por_segundo = crudo.resample("1s").mean()
desde, hasta = bloque_contiguo_mas_largo((por_segundo > 3.0).to_numpy())
```

Código 2: Extracción de la altitud y aislamiento del tramo en vuelo

Series originales y necesidad de diferenciar (punto 2)

Series de tráfico

La Figura 1 presenta ambas series de tráfico en niveles. El rasgo dominante es una oscilación regular que se repite cada veinticuatro horas, superpuesta a fluctuaciones de mayor frecuencia.




Figura 1

Series de tráfico en niveles, con frecuencia horaria

La naturaleza de esa oscilación se aprecia con mayor claridad en la Figura 2, que promedia el volumen para cada hora del día. Ambas series describen un valle nocturno y un máximo vespertino. El balanceador alcanza su mínimo a las 07:00 y su máximo a las 21:00; la interfaz de punto de venta, su mínimo a las 08:00 y su máximo a las 19:00. La amplitud del ciclo supera el diez por ciento del nivel medio, magnitud que no admite tratarse como ruido.




Figura 2

Perfil medio por hora del día. La banda representa el rango intercuartílico; las líneas verticales señalan el máximo y el mínimo

La Figura 3 despliega la misma información sobre dos dimensiones y confirma la regularidad del ciclo diario a lo largo de toda la semana.




Figura 3

Solicitudes medias según día de la semana y hora del día

Esta última figura revela además un rasgo que el trabajo no modela: en la serie del balanceador, los días miércoles y jueves presentan niveles sensiblemente inferiores al resto de la semana. Existe, por lo tanto, un efecto de día de la semana además del ciclo diario. El período muestral de un mes ofrece apenas cuatro repeticiones de cada día, cantidad insuficiente para estimar con fiabilidad una componente estacional de período 168. La limitación se retoma en las conclusiones.

La Figura 4 compara el efecto de distintos esquemas de diferenciación. La diferencia estacional de veinticuatro horas elimina el ciclo; la aplicación adicional de una diferencia regular corrige el

desplazamiento residual del nivel.




Figura 4

Efecto de la diferencia estacional y de su combinación con la diferencia regular


Serie de altitud

La Figura 5 presenta la serie de altitud en niveles y su primera diferencia. El comportamiento difiere por completo del anterior: no hay ciclo repetitivo sino un recorrido con fases sucesivas de despegue, ascenso, crucero y descenso. La media se desplaza sin retorno, señal visual de no estacionariedad. La primera diferencia oscila en torno a cero con dispersión estable.


Funciones de autocovarianza, autocorrelación y autocorrelación parcial (punto 3)

La Figura 6 presenta las tres funciones para las series de tráfico. El rasgo determinante son los picos pronunciados en los rezagos 24, 48 y 72, que confirman la periodicidad diaria y fijan el período estacional en $s = 24$. La autocorrelación no decae hacia cero entre esos picos, lo cual indica que la componente estacional domina la estructura. La Figura 7 reproduce el mismo conjunto para la serie de punto de venta, con un patrón equivalente.


La Figura 8 presenta el mismo conjunto para la serie de altitud, en niveles y tras diferenciar. El contraste ilustra el concepto expuesto en el marco teórico con más claridad que cualquier descripción. En niveles, la autocorrelación de primer orden alcanza 0,96 y decae con lentitud casi lineal, mientras la parcial exhibe un primer rezago cercano a la unidad y se corta de inmediato. La teoría asocia ese par de patrones a un proceso integrado: la persistencia no proviene de una memoria autorregresiva de orden elevado sino de la presencia de una raíz unitaria, y el remedio es la diferenciación.

**Figura 5**


Altitud relativa del vuelo en niveles y en primera diferencia

**Figura 6**


Funciones FAS, FAC y FACP de la serie del balanceador de carga

**Figura 7**

Funciones FAS, FAC y FACP de la serie de punto de venta

**Figura 8**

Funciones FAS, FAC y FACP de la altitud en niveles

**Figura 9**

Funciones FAS, FAC y FACP de la altitud tras una diferencia regular

Tras la diferenciación, la autocorrelación pierde la persistencia y conserva significatividad únicamente en los primeros rezagos, patrón compatible con una componente de medias móviles de orden bajo. El material identificado, visible en la Figura 9, corresponde a un modelo $ARIMA(p, 1, q)$ con órdenes reducidos.

Pruebas de raíces unitarias (punto 4)

La Tabla 3 reúne los resultados de ambos contrastes sobre las series de tráfico en sus distintas versiones.

La lectura conjunta revela un matiz que un contraste aislado ocultaría. Sobre la serie del balancador en niveles, ambas pruebas coinciden en la estacionariedad. Sobre la serie de punto de venta en niveles, en cambio, discrepan: la prueba de Dickey-Fuller aumentada rechaza la raíz unitaria, pero la KPSS rechaza también la estacionariedad. Esa configuración es típica de series con componente estacional marcada, donde cada contraste interpreta la estructura periódica de un modo distinto.

El caso de la serie de altitud aporta un tercer escenario. La prueba de Dickey-Fuller aumentada arroja $p = 0,1237$ y no rechaza la raíz unitaria; la KPSS arroja $p \geq 0,10$ y tampoco rechaza la estacionariedad. Ninguna de las dos se pronuncia.

Ante esa indefinición, la decisión de diferenciar se sostiene sobre tres elementos convergentes:

Tabla 3*Contrastes de raíces unitarias sobre las series de tráfico*

Serie	Versión	ADF	p	KPSS	p
Balanceador	original	-4,53	0,00	0,41	0,07
Balanceador	difer. regular	-9,70	0,00	0,17	0,10
Balanceador	difer. estacional	-7,56	0,00	0,54	0,03
Balanceador	ambas diferencias	-10,10	0,00	0,02	0,10
Punto de venta	original	-9,55	0,00	2,33	0,01
Punto de venta	difer. regular	-10,82	0,00	0,13	0,10
Punto de venta	difer. estacional	-6,21	0,00	0,02	0,10
Punto de venta	ambas diferencias	-10,43	0,00	0,24	0,10

el desplazamiento visible de la media, el decaimiento lento de la autocorrelación junto con el corte abrupto de la parcial, y la ausencia de rechazo por parte de la prueba de Dickey-Fuller aumentada. La literatura recomienda diferenciar ante evidencia de raíz unitaria, porque sobrediferenciar cuesta menos que estimar sobre una serie integrada (Hyndman & Athanasopoulos, 2021).

El resultado decisivo aparece tras la diferenciación. La prueba de Ljung-Box aplicada a la serie de altitud diferenciada arroja $p = 1,115 \times 10^{-62}$ y rechaza la incorrelación sin margen de duda. Subsiste, por lo tanto, estructura autocorrelacionada genuina, y existe un modelo por estimar.

```
p_adf = adfuller(datos)[1] # HO: existe raiz unitaria
p_kpss = kpss(datos, nlags="auto")[1] # HO: la serie es estacionaria
```

Código 3: Aplicación conjunta de ambos contrastes

Estimación y selección de modelos (punto 5)

Series de tráfico

Se estimó una grilla de modelos SARIMA con período estacional $s = 24$, con distintas combinaciones de diferencia regular y estacional. La Tabla 4 presenta los ocho modelos resultantes.

La comparación emplea dos criterios complementarios. Los criterios de información miden el ajuste dentro de la muestra y penalizan la cantidad de parámetros; el desempeño sobre el conjunto de prueba evalúa la capacidad predictiva efectiva. Cuando ambos coinciden, la elección es inmediata; cuando discrepan, se privilegia el desempeño fuera de muestra, que atiende directamente a la finalidad predictiva del modelo.

En la serie del balanceador ambos criterios coinciden: la especificación $(1, 1, 1) \times (1, 1, 1)_{24}$ minimiza simultáneamente el criterio de Akaike y el error de predicción.

En la serie de punto de venta, en cambio, **los criterios discrepan**. El de Akaike favorece la especificación $(1, 0, 1) \times (1, 1, 1)_{24}$, con un valor de 15.381,30; el desempeño sobre el conjunto de prueba favorece $(1, 1, 1) \times (1, 0, 1)_{24}$, cuyo error porcentual absoluto medio cae casi un tercio, 3,90 frente a 5,09 por ciento.

Tabla 4

Comparación de modelos SARIMA estimados

Serie	Modelo	AIC	BIC	MAE	MAPE
Balanceador	$(1, 1, 1) \times (1, 1, 1)_{24}$	15.491,11	15.513,46	16.662	0,79 %
Balanceador	$(1, 0, 1) \times (1, 1, 1)_{24}$	15.527,20	15.549,55	26.776	1,26 %
Balanceador	$(1, 1, 1) \times (1, 0, 1)_{24}$	16.229,29	16.251,82	76.284	3,74 %
Balanceador	$(1, 0, 1) \times (1, 0, 1)_{24}$	16.264,80	16.287,34	74.059	3,64 %
Punto de venta	$(1, 0, 1) \times (1, 1, 1)_{24}$	<i>15.381,30</i>	15.403,47	39.594	5,09 %
Punto de venta	$(1, 1, 1) \times (1, 1, 1)_{24}$	15.467,63	15.489,79	45.861	5,91 %
Punto de venta	$(1, 1, 1) \times (1, 0, 1)_{24}$	15.737,10	15.759,45	29.641	3,90 %
Punto de venta	$(1, 0, 1) \times (1, 0, 1)_{24}$	15.860,56	15.882,91	30.840	4,08 %

Nota. En negrita, el modelo seleccionado para cada serie. En cursiva, el valor mínimo del criterio de Akaike cuando no corresponde al modelo seleccionado.

Se adopta esta última. La discrepancia admite una lectura sustantiva: la diferencia estacional mejora el ajuste dentro de la muestra pero deteriora la predicción, comportamiento característico de una componente estacional menos estable que en la serie del balanceador. El criterio empleado es el mismo que se aplica más adelante al seleccionar el orden del modelo multivariado, donde la divergencia entre criterios se manifiesta con mayor intensidad.

El examen de significatividad individual deja un resultado incómodo, que este informe prefiere exponer antes que atenuar. En el modelo del balanceador, los parámetros de la parte regular carecen de significatividad: el coeficiente autorregresivo alcanza $-0,08$ con $p = 0,97$, y el de medias móviles $0,01$ con $p = 1,00$. Los parámetros estacionales, en cambio, son altamente significativos: $-0,15$ con $p < 0,001$ para el autorregresivo y $-0,52$ con $p < 0,001$ para el de medias móviles.

La lectura es que la estructura de la serie reside casi por completo en su componente estacional, y la parte regular del modelo sobra. Una especificación $(0, 1, 0) \times (1, 1, 1)_{24}$ habría alcanzado un ajuste equivalente con dos parámetros menos.

Serie de altitud

Sobre la serie de altitud se estimó una grilla ARIMA($p, 1, q$) con órdenes entre cero y tres. El criterio de Akaike selecciona ARIMA(1, 1, 3), con un valor de 1.379,95.

```
for p in range(4):
    for q in range(4):
        ajuste = ARIMA(entrenamiento, order=(p, 1, q)).fit()
        resultados.append({"modelo": f"ARIMA({p},1,{q})", "AIC": ajuste.aic})
```

Código 4: Grilla de modelos y selección por criterio de información

A diferencia del caso anterior, los cuatro parámetros son individualmente significativos al cinco por ciento, según se detalla en la Tabla 5.

La significatividad conjunta se evaluó mediante el contraste de razón de verosimilitud contra el modelo restringido ARIMA(0, 1, 0), equivalente a un paseo aleatorio sin parámetros. El estadístico

Tabla 5*Parámetros del modelo ARIMA(1, 1, 3) de la serie de altitud*

Parámetro	Coficiente	Error estándar	z	$P > z $
ϕ_1	-0,2650	0,120	-2,208	0,027
θ_1	1,6263	0,113	14,432	< 0,001
θ_2	1,2023	0,136	8,821	< 0,001
θ_3	0,4268	0,061	6,959	< 0,001
σ^2	1,3022	0,051	25,344	< 0,001

alcanza 567,11 con cuatro grados de libertad y un valor p del orden de 2×10^{-121} . La hipótesis nula de nulidad conjunta se rechaza sin margen de duda.

```

modelo_nulo = ARIMA(entrenamiento, order=(0, 1, 0)).fit()
estadistico_lr = 2 * (modelo.llf - modelo_nulo.llf)
p_valor = stats.chi2.sf(estadistico_lr, len(modelo.params) - len(modelo_nulo.params))

```

Código 5: Contraste de significatividad global por razón de verosimilitud

Desempeño y comparación entre modelos (puntos 6 y 7)

La partición entre entrenamiento y prueba reservó las últimas 48 horas en las series de tráfico y los últimos 15 segundos en la de altitud. Ambos horizontes guardan proporción con la frecuencia de muestreo y con el tamaño de la muestra. La Tabla 6 reúne el desempeño de los modelos seleccionados.

Tabla 6*Desempeño de los modelos seleccionados sobre el conjunto de prueba*

Serie	Modelo	MAE	RMSE	MAPE
Balanceador	SARIMA(1, 1, 1) $\times$ (1, 1, 1) ₂₄	16.662	20.310	0,79 %
Punto de venta	SARIMA(1, 1, 1) $\times$ (1, 0, 1) ₂₄	29.641	58.454	3,90 %
Altitud (m)	ARIMA(1, 1, 3)	6,01	7,53	—

La comparación entre modelos, presentada en la Tabla 4, muestra cuánto separa a las especificaciones con diferencia estacional de las que carecen de ella. En la serie del balanceador, el error absoluto medio se multiplica por cuatro al omitirla. La componente estacional es, pues, el elemento decisivo.

En el caso de la serie de altitud, las diferencias entre órdenes vecinos son mínimas: los cuatro mejores modelos por criterio de Akaike presentan errores absolutos medios comprendidos entre 5,99 y 6,01 metros. El desempeño predictivo no discrimina, y el criterio de información opera como desempate en favor de la especificación más parsimoniosa.

Corresponde advertir que el conjunto de prueba de la serie de altitud coincide con la fase de descenso, dinámicamente distinta del cruce donde el modelo se entrena en su mayor parte. La

métrica obtenida peca, pues, de conservadora.

Diagnóstico de residuos (punto 8)

El diagnóstico arroja resultados netamente distintos entre las series de tráfico y la de altitud, y conviene exponerlos por separado.

Serie de tráfico

La Tabla 7 presenta la prueba de Ljung-Box sobre los residuos de ambos modelos.

Tabla 7

Prueba de Ljung-Box sobre los residuos de los modelos SARIMA

Serie	Rezago	Estadístico	p
Balanceador	12	17,40	0,14
Balanceador	24	43,64	0,01
Balanceador	48	212,49	< 0,001
Punto de venta	12	86,58	< 0,001
Punto de venta	24	92,07	< 0,001
Punto de venta	48	112,38	< 0,001

El resultado es desfavorable y así debe consignarse. En la serie del balanceador, los residuos superan el contraste hasta el rezago 12, pero lo incumplen a partir del rezago 24. En la serie de punto de venta, el rechazo se verifica en todos los rezagos examinados.

La implicación es que ambos modelos dejan estructura sin explicar, concentrada en los rezagos correspondientes al ciclo diario y a sus múltiplos. El patrón concuerda con lo observado en el mapa de calor: existe una componente semanal que los modelos no capturan, y que se manifiesta como autocorrelación residual en los rezagos estacionales.


Las Figuras 10 y 11 muestran ese comportamiento: la función de autocorrelación de los residuos conserva coeficientes significativos en los rezagos múltiplos de veinticuatro.

En consecuencia, los pronósticos de estas dos series deben interpretarse con menor confianza que la sugerida por sus métricas de error, y los intervalos de predicción son probablemente demasiado estrechos.


Serie de altitud

El diagnóstico del modelo ARIMA(1,1,3) arroja el resultado opuesto. La prueba de Ljung-Box no rechaza la incorrelación en ninguno de los rezagos examinados: $p = 0,976$ en el rezago 10, $p = 0,631$ en el 20 y $p = 0,487$ en el 30. Los residuos tienen media de 0,0136 metros y desvío estándar de 1,1644 metros.


La Figura 12 confirma el resultado: los coeficientes de la función de autocorrelación de los residuos permanecen dentro de la banda de significatividad, y el gráfico temporal no evidencia cambios sistemáticos de nivel ni de dispersión.

**Figura 10**

Diagnóstico de residuos del modelo de la serie del balanceador de carga

**Figura 11**

Diagnóstico de residuos del modelo de la serie de punto de venta

**Figura 12**

Diagnóstico de residuos del modelo de la serie de altitud

El modelo no deja estructura autocorrelacionada sin explicar. El contraste de Jarque-Bera (Jarque & Bera, 1980), en cambio, rechaza la normalidad con un estadístico de 431,74, asimetría de 0,51 y curtosis de 7,74. Los apartamientos se concentran en las colas y se explican por las maniobras del vuelo; afectan la validez de los intervalos de confianza nominales, no la estimación puntual.

Pronósticos (punto 9)

La Figura 13 presenta los pronósticos a 48 horas de las series de tráfico. El horizonte equivale a dos ciclos diarios completos, ventana que permite verificar si el modelo reproduce la periodicidad sin extrapolar en exceso. La Figura 14 presenta el correspondiente a la serie de punto de venta.




Figura 13

Pronóstico a 48 horas de la serie del balanceador de carga





Figura 14

Pronóstico a 48 horas de la serie de punto de venta

La Figura 15 presenta el pronóstico a 15 segundos de la serie de altitud. El horizonte responde a la frecuencia de un hertz y al tamaño de la muestra, y representa poco más del tres por ciento de las observaciones. Un horizonte de 45 segundos eleva el error absoluto medio por encima de los 18 metros, dado que abarca la maniobra de descenso completa.

**Figura 15**

Pronóstico a 15 segundos de la serie de altitud, con intervalo de confianza

Modelo de vectores autorregresivos (punto 10)

Alcance y restricción de calendario

El modelo multivariado se construye sobre las dos series de tráfico. La serie de altitud queda excluida por una razón que no admite solución dentro del conjunto de datos disponible: fue registrada en 2018, mientras que las series de tráfico corresponden a 2026. Los calendarios son disjuntos y no comparten un solo instante de observación. Un modelo de vectores autorregresivos exige series alineadas sobre el mismo eje temporal, de modo que construirlo con las tres es técnicamente imposible.

Las dos series de tráfico tampoco coinciden por completo. La intersección temporal abarca desde el 18 de julio hasta el 31 de julio de 2026, esto es, trece días. Tras aplicar la transformación logarítmica y la diferencia estacional restan 289 observaciones.

```
alineadas = pd.concat([alb, pos], axis=1, join="inner").dropna()
datos_var = np.log1p(alineadas).diff(24).dropna()
```

Código 6: Alineación temporal y transformación previa al modelo multivariado

Selección del orden de rezagos

Los cuatro criterios de selección no coinciden, según muestra la Tabla 8.

La discrepancia tiene consecuencias considerables. Con dos variables y 24 rezagos, el modelo estima 98 parámetros a partir de 241 observaciones de entrenamiento, relación que compromete la fiabilidad de las estimaciones. Con dos rezagos, el número desciende a 10.

El desempeño fuera de muestra resuelve el empate. La Tabla 9 compara especificaciones alternativas mediante métricas calculadas sobre la escala original.

Tabla 8

Orden de rezagos sugerido por cada criterio

Criterio	Rezagos
Akaike	24
Bayesiano	2
Hannan-Quinn	2
Error de predicción final	24

Tabla 9

Comparación de especificaciones del modelo multivariado a 48 horas

Rezagos	Parám.	MAE bal.	MAPE bal.	MAE p. venta	MAPE p. venta
1	6	31.287	1,48 %	32.128	4,67 %
2	10	27.826	1,31 %	31.455	4,59 %
3	14	26.275	1,24 %	30.781	4,51 %
24	98	36.008	1,71 %	26.932	4,03 %

El resultado es un caso de manual de sobreajuste. La especificación con 24 rezagos, pese a emplear casi diez veces más parámetros, predice *peor* la serie del balanceador que la de dos rezagos. Su única ventaja aparece en la serie de punto de venta, donde reduce el error absoluto medio un catorce por ciento, mejora que no compensa multiplicar por diez el número de parámetros.

Se adopta entonces la especificación con **dos rezagos**, respaldada por dos criterios de información y por el desempeño fuera de muestra. La alternativa de tres rezagos mejora levemente ambas métricas, pero ningún criterio de información la respalda.

Sobre la medición del error


Las métricas de la Tabla 9 se calculan sobre la escala original, en solicitudes, tras invertir la transformación aplicada. La precisión no es accesoria. Calculadas sobre la serie transformada, que oscila en torno a cero, las mismas predicciones arrojaban un error porcentual absoluto medio del 97,20 por ciento, cifra que sugería un modelo inservible.

El valor no reflejaba la calidad del modelo sino la inadecuación de la métrica: al dividir por un denominador próximo a cero, el error porcentual se vuelve inestable y carece de interpretación (Hyndman & Koehler, 2006). Expresado en la escala original, el mismo modelo alcanza un error del 1,31 por ciento.

```
for i, t in enumerate(indice_prueba):
    base = historico.loc[t - pd.Timedelta(hours=24)]
    historico.loc[t] = base + pronostico_transformado.iloc[i]
prediccion = np.expm1(historico.reindex(indice_prueba).to_numpy())
```

Código 7: Inversión de la transformación previa al cálculo de métricas

La Figura 16 presenta el pronóstico resultante sobre la escala original.

**Figura 16**

Pronóstico del modelo multivariado a 48 horas, expresado en la escala original

Impulso-respuesta y causalidad (punto 11)

La Figura 17 presenta las funciones impulso-respuesta ortogonalizadas del modelo adoptado. Las respuestas se extinguen con rapidez, comportamiento esperable en una especificación de orden bajo sobre series ya estacionarias.

La Tabla 10 presenta los contrastes de causalidad de Granger.


Tabla 10

Contrastes de causalidad de Granger sobre el modelo adoptado

Variable causante	Variable causada	F	p	Decisión al 5 %
Punto de venta	Balanceador	3,554	0,0294	Se rechaza H_0
Balanceador	Punto de venta	0,065	0,9369	No se rechaza H_0

El resultado es unidireccional. Los rezagos de la serie de punto de venta contribuyen a explicar la serie del balanceador, mientras que la relación inversa no alcanza significatividad, con un valor p que se aproxima a la unidad.

La interpretación admite una lectura operativa plausible: el tráfico de la interfaz de punto de venta es una porción del tráfico total que atraviesa el balanceador, de modo que un movimiento en el primero antecede a un movimiento en el agregado. Conviene subrayar, no obstante, la advertencia formulada en el marco teórico. La causalidad de Granger establece precedencia temporal con contenido predictivo, no causalidad estructural. Con trece días de solapamiento y 241 observaciones

**Figura 17**

Funciones impulso-respuesta ortogonalizadas del modelo de dos rezagos

de entrenamiento, la evidencia debe considerarse indicativa.

Estacionalidad y representación mediante SARIMA (punto 12)

Las dos series de tráfico presentan estacionalidad diaria y quedan representadas por modelos SARIMA con período $s = 24$. La comparación solicitada refiere a los modelos determinados con anterioridad dentro de este mismo trabajo, esto es, a las especificaciones sin componente estacional evaluadas en la grilla del punto 5.

Esa comparación, contenida en la Tabla 4, no deja lugar a dudas. En la serie del balanceador, la omisión de la diferencia estacional eleva el error absoluto medio de 16.662 a 76.284 solicitudes, esto es, lo multiplica por más de cuatro, y el criterio de Akaike se deteriora en más de 700 unidades. Incorporar la componente estacional es, pues, lo que decide el ajuste.

La serie de altitud, en cambio, carece de estacionalidad. El periodograma de la serie diferenciada señala un período dominante de 16,3 segundos, pero ese pico no sobrevive al contraste con la función de autocorrelación: en el rezago 16 el coeficiente llega a 0,086, por debajo de la banda de significatividad de $\pm 0,092$ que corresponde a una muestra de este tamaño. El pico es espurio. El episodio muestra el riesgo de leer un periodograma por separado, sin verificar sus máximos contra la autocorrelación.

La ausencia responde a la naturaleza del fenómeno: la altitud de una aeronave durante un vuelo

único obedece al plan de vuelo y a la acción del piloto automático, sin ciclo repetitivo de período fijo. La representación adecuada es, pues, un modelo ARIMA sin componente estacional.

Conclusiones

Hallazgos principales

El trabajo modeló tres series de naturaleza distinta y obtuvo resultados de calidad desigual, circunstancia que conviene exponer sin uniformar.

Las dos series de tráfico presentan estacionalidad diaria inequívoca, con período de veinticuatro horas, verificada tanto por la inspección del perfil horario como por los picos de la función de autocorrelación en los rezagos 24, 48 y 72. Los modelos SARIMA seleccionados alcanzan errores porcentuales del 0,79 y del 3,90 por ciento sobre un horizonte de 48 horas, magnitudes aceptables para una serie de tráfico operativo.

Ese desempeño, sin embargo, convive con un diagnóstico de residuos desfavorable. La prueba de Ljung-Box rechaza la incorrelación a partir del rezago 24 en la serie del balanceador, y en todos los rezagos examinados en la serie de punto de venta. Ambos modelos dejan estructura sin explicar, concentrada en los rezagos estacionales. Los pronósticos merecen, por lo tanto, menor confianza que la sugerida por sus métricas de error.

La serie de altitud presenta el comportamiento opuesto. Sin componente estacional, es un proceso integrado que una sola diferencia regular vuelve estacionario. El modelo ARIMA(1, 1, 3) exhibe parámetros significativos tanto individual como conjuntamente, y sus residuos no se distinguen del ruido blanco en ningún rezago examinado. Es el único de los tres que supera el diagnóstico sin reservas.

El modelo multivariado, construido sobre las dos series de tráfico con dos rezagos, arroja una relación de precedencia unidireccional: los rezagos de la serie de punto de venta contribuyen a explicar la del balanceador, sin reciprocidad.

Dos lecciones metodológicas

Dos episodios del trabajo trascienden el resultado particular.

El primero es la selección del orden en el modelo multivariado. El criterio de Akaike sugería 24 rezagos, esto es, 98 parámetros estimados a partir de 241 observaciones. La especificación resultante predecía peor que una de diez parámetros. Los criterios de información orientan, no dictaminan, y ante discrepancia entre ellos el desempeño fuera de muestra es el árbitro más confiable. La misma tensión reapareció, con menor intensidad, al seleccionar el modelo estacional de la serie de punto de venta.

El segundo es de orden más elemental: una métrica mal elegida puede invertir por completo la lectura de un resultado. El error porcentual absoluto medio del 97,20 por ciento que arrojaba el modelo multivariado no medía su calidad sino la inadecuación de aplicar una métrica relativa sobre una serie que oscila alrededor de cero. Expresado en la escala original, el mismo modelo alcanza un error del 1,31 por ciento.

Límites del trabajo

1. **Tamaño muestral.** Las series de tráfico abarcan aproximadamente un mes, y la de altitud, 457 observaciones. Ninguna admite validación mediante ventanas móviles ni evaluación sobre múltiples horizontes independientes.
2. **Estacionalidad semanal no modelada.** El mapa de calor revela que la serie del balanceador presenta niveles sensiblemente inferiores los días miércoles y jueves. Un período muestral de un mes ofrece apenas cuatro repeticiones de cada día de la semana, cantidad insuficiente para estimar una componente estacional de período 168. La autocorrelación residual detectada en el diagnóstico encaja con esa omisión.
3. **Solapamiento limitado entre las series de tráfico.** La intersección temporal abarca trece días y 289 observaciones tras la transformación. Toda conclusión del modelo multivariado queda condicionada por esa brevedad.
4. **Calendarios disjuntos.** La serie de altitud no participa del modelo multivariado por corresponder a un período que no solapa con el de las restantes. La limitación es estructural y no admite solución dentro de los datos disponibles.
5. **Alcance de la causalidad de Granger.** El contraste establece precedencia temporal con contenido predictivo. No autoriza a afirmar que una serie cause a la otra en sentido estructural.
6. **Un único vuelo.** Los resultados de la serie de altitud describen ese vuelo. No se generalizan a otros vuelos ni a otras aeronaves.
7. **Normalidad de los residuos.** El contraste de Jarque-Bera rechaza la normalidad en el modelo de la serie de altitud. Los intervalos de predicción nominales son, por eso, aproximados.

Líneas de trabajo futuro

La limitación de mayor peso es la brevedad del período muestral, y corregirla destrabaría las restantes. Un año de registro permitiría estimar la componente semanal cuya ausencia se manifiesta en la autocorrelación residual, y ampliaría el solapamiento entre las series de tráfico hasta un tamaño donde el modelo multivariado admitiera órdenes superiores sin comprometer la fiabilidad.

En segundo término, el modelo del balanceador se puede simplificar. Los parámetros de la parte regular carecen de significatividad, de modo que una especificación $(0, 1, 0) \times (1, 1, 1)_{24}$ alcanzaría un ajuste equivalente con dos parámetros menos.

Por último, la serie de altitud ofrece una extensión natural que este trabajo no exploró: la telemetría de vuelo registra en paralelo la velocidad aerodinámica junto con la altitud, y ambas magnitudes están vinculadas por el intercambio entre energía potencial y cinética. Un modelo multivariado sobre ese par contaría con series perfectamente alineadas y con una interpretación física directa de la función impulso-respuesta.

Declaración de uso de IA generativa

Siguiendo las recomendaciones de transparencia para citar y describir el uso de IA generativa en trabajos académicos (McAdoo et al., 2025), se declara que durante el desarrollo de este trabajo se emplearon agentes de IA generativa como apoyo para la exploración del repositorio, el desarrollo y la revisión del código, y la redacción y edición del documento. Las herramientas utilizadas fueron OpenAI Codex, con la configuración GPT-5.5 xhigh, y Claude Code, con el modelo Opus (Anthropic, 2026; OpenAI, 2026). El uso de estas herramientas tuvo carácter asistivo: las decisiones metodológicas, la selección de datos, la ejecución de los análisis, la validación de resultados y la responsabilidad final del informe corresponden a los autores.

Referencias bibliográficas

- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716-723. <https://doi.org/10.1109/TAC.1974.1100705>
- Anthropic. (2026). Claude Code (Opus) [Agente de codificación con IA generativa]. <https://docs.anthropic.com/en/docs/claude-code/getting-started>
- BodegaAI. (2026a). Registro horario de solicitudes atendidas por el balanceador de carga de producción, julio de 2026 [Conjunto de datos no publicado].
- BodegaAI. (2026b). Registro horario de solicitudes por destino de la interfaz de punto de venta, julio y agosto de 2026 [Conjunto de datos no publicado].
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Wiley.
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427-431. <https://doi.org/10.1080/01621459.1979.10482531>
- Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3), 424-438. <https://doi.org/10.2307/1912791>
- Hannan, E. J., & Quinn, B. G. (1979). The determination of the order of an autoregression. *Journal of the Royal Statistical Society: Series B (Methodological)*, 41(2), 190-195. <https://doi.org/10.1111/j.2517-6161.1979.tb01072.x>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Jarque, C. M., & Bera, A. K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3), 255-259. [https://doi.org/10.1016/0165-1765\(80\)90024-5](https://doi.org/10.1016/0165-1765(80)90024-5)
- Keipour, A., Mousaei, M., & Scherer, S. (2020). ALFA: A dataset for UAV fault and anomaly detection [Conjunto de datos]. https://kithub.cmu.edu/articles/dataset/ALFA_A_Dataset_for_UAV_Fault_and_Anomaly_Detection/12707963
- Keipour, A., Mousaei, M., & Scherer, S. (2021). ALFA: A dataset for UAV fault and anomaly detection. *The International Journal of Robotics Research*, 40(2-3), 515-520. <https://doi.org/10.1177/0278364920966642>
- Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root: How sure are we that economic time series have a unit root? *Journal of Econometrics*, 54(1-3), 159-178. [https://doi.org/10.1016/0304-4076\(92\)90104-Y](https://doi.org/10.1016/0304-4076(92)90104-Y)
- Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297-303. <https://doi.org/10.1093/biomet/65.2.297>

- McAdoo, T., Denny, S., & Lee, C. (2025, 9 de septiembre). *Citing generative AI in APA Style: Part 1—Reference formats*. American Psychological Association. Consultado el 24 de agosto de 2026, desde <https://apastyle.apa.org/blog/cite-generative-ai-references>
- OpenAI. (2026). Codex (GPT-5.5 xhigh) [Agente de codificación con IA generativa]. <https://openai.com/codex/>
- Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461-464. <https://doi.org/10.1214/aos/1176344136>
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92-96. <https://doi.org/10.25080/Majora-92bf1922-011>
- Sims, C. A. (1980). Macroeconomics and reality. *Econometrica*, 48(1), 1-48. <https://doi.org/10.2307/1912017>

Apéndice A

Apéndice A. Material gráfico complementario

Las figuras de este apéndice documentan el análisis exploratorio de las series de tráfico. Se excluyeron del cuerpo por resultar redundantes respecto de figuras allí incluidas, o por referir a aspectos que el trabajo no modela.




Figura A1

Serie horaria del balanceador de carga, análisis exploratorio


Apéndice B

Apéndice B. Rutinas de cómputo


Construcción de la serie de altitud

La rutina siguiente extrae la altitud del registro binario de telemetría, la lleva a una grilla regular de un segundo y aísla el tramo contiguo más extenso en vuelo.


```
def leer_altitud(ruta):
    """Extrae la altitud relativa, en metros, de un registro MAVLink."""
    conexion = mavutil.mavlink_connection(ruta)
```

**Figura A2**


Serie horaria de punto de venta, análisis exploratorio

**Figura A3**

Agregación diaria de la serie del balanceador de carga

**Figura A4**


Agregación diaria de la serie de punto de venta

**Figura A5**


Patrón por día de la semana, serie del balanceador de carga

```
registros = []
while True:
    mensaje = conexion.recv_match(type="GLOBAL_POSITION_INT")
    if mensaje is None:
        break
    registros.append((mensaje._timestamp, mensaje.relative_alt / 1000.0))
crudo = pd.DataFrame(registros, columns=["timestamp", "altitud_m"])
crudo["timestamp"] = pd.to_datetime(crudo["timestamp"], unit="s")
return crudo.set_index("timestamp")["altitud_m"]


def bloque_contiguo_mas_largo(mascara):
```

**Figura A6**


Patrón por día de la semana, serie de punto de venta

**Figura A7**


Media y desvío estándar móviles, serie del balanceador de carga

**Figura A8**

Media y desvío estándar móviles, serie de punto de venta

**Figura A9**

Descomposición estacional de la serie del balanceador de carga

**Figura A10**

Descomposición estacional de la serie de punto de venta




Figura A11

Ajuste sobre el conjunto de prueba, serie del balanceador de carga




Figura A12

Ajuste sobre el conjunto de prueba, serie de punto de venta

```

"""Indices de inicio y fin del tramo contiguo mas largo que cumple la mascara."""
mejor_inicio, mejor_largo = 0, 0
inicio = None
for posicion, activo in enumerate(mascara):
    if activo and inicio is None:
        inicio = posicion
    elif not activo and inicio is not None:
        if posicion - inicio > mejor_largo:
            mejor_inicio, mejor_largo = inicio, posicion - inicio
        inicio = None
if inicio is not None and len(mascara) - inicio > mejor_largo:
    mejor_inicio, mejor_largo = inicio, len(mascara) - inicio
return mejor_inicio, mejor_inicio + mejor_largo

```

Representación conjunta de las tres funciones

```

def graficar_fas_fac_facp(datos, titulo, rezagos=40):
    """Grafica autocovarianza, autocorrelacion y parcial en una sola figura."""
    figura, ejes = plt.subplots(1, 3, figsize=(13, 3.4))
    autocovarianza = sm.tsa.acovf(datos, nlag=rezagos, fft=True)
    ejes[0].stem(range(len(autocovarianza)), autocovarianza, basefmt=" ")
    ejes[0].set_title("FAS - autocovarianza")

```

```
plot_acf(datos, lags=rezagos, ax=ejes[1], title="FAC - autocorrelacion")
plot_pacf(datos, lags=rezagos, ax=ejes[2], method="ywm",
          title="FACP - autocorrelacion parcial")
figura.suptitle(titulo, y=1.05)
plt.tight_layout()
plt.show()
```

Comparación de especificaciones del modelo multivariado

La rutina siguiente evalúa cada orden de rezagos e invierte la transformación antes de calcular las métricas, de modo que el error quede expresado en la escala original.

```
def evaluar(p, entrenamiento, prueba, log_original, alineadas, horizonte):
    resultado = VAR(entrenamiento).fit(p)
    pronostico = pd.DataFrame(
        resultado.forecast(entrenamiento.values[-p:], horizonte),
        index=prueba.index, columns=prueba.columns)
    filas = []
    for columna in prueba.columns:
        historico = log_original[columna].copy()
        prediccion = []
        for i, t in enumerate(prueba.index):
            base = historico.loc[t - pd.Timedelta(hours=24)]
            valor = base + pronostico[columna].iloc[i]
            historico.loc[t] = valor
            prediccion.append(valor)
        estimado = np.expml(np.array(prediccion))
        real = alineadas[columna].reindex(prueba.index).to_numpy()
        filas.append({
            "rezagos": p,
            "serie": columna,
            "MAE": np.mean(np.abs(estimado - real)),
            "RMSE": np.sqrt(np.mean((estimado - real) ** 2)),
            "MAPE": np.mean(np.abs((estimado - real) / real)) * 100,
        })
    return filas
```