

**Pronóstico de series temporales de infraestructura
productiva mediante modelos de aprendizaje automático,
aprendizaje profundo e híbridos**

*Modelado y pronóstico mediante Machine Learning, Deep Learning,
modelos híbridos, AutoML y modelos de fundación*

Trabajo Práctico N.º 2

Análisis de Series Temporales
Maestría en Ciencia de Datos
Universidad Austral

Docente

Rodrigo Del Rosso

Integrantes

Carlos Aular

Juan Martín Pedrozo

Fecha de entrega: septiembre de 2026

Resumen ejecutivo

El presente trabajo continúa el análisis desarrollado en el Trabajo Práctico N.º 1 sobre dos series horarias de infraestructura productiva de la empresa BodegaAI: la cantidad total de solicitudes atendidas por el balanceador de carga (*RequestCount*, serie ALB) y la cantidad de solicitudes por destino del servicio de tienda (*RequestCountPerTarget*, serie store-service). El historial disponible se extiende de un mes, en el trabajo anterior, a aproximadamente tres meses (2,063 observaciones horarias por serie, entre el 3 de julio y el 26 de septiembre de 2026, una vez descartada la rampa de encendido del balanceador). Una tercera serie, pública e independiente de BodegaAI (visitas horarias de usuarios a Wikipedia en español, con el mismo calendario), se incorpora como contraste acotado, con seis modelos de hiperparámetros por defecto.

El objetivo consiste en determinar si los modelos de aprendizaje automático (Machine Learning), aprendizaje profundo (Deep Learning), modelos híbridos, herramientas de AutoML y modelos de fundación superan, bajo un protocolo honesto de validación, el desempeño de los modelos clásicos utilizados en el trabajo anterior (SARIMA). Se evaluaron 32 configuraciones por cada serie de BodegaAI, agrupadas en diez familias: referencias ingenuas, modelos estadísticos clásicos, la reestimación del SARIMA del Trabajo Práctico N.º 1, árboles de decisión con boosting y ensambles, redes neuronales profundas, Prophet y NeuralProphet, un híbrido de descomposición estacional con boosting, dos plataformas de AutoML y un modelo de fundación de series temporales (Chronos). La selección del modelo final se realizó exclusivamente por el error absoluto medio (MAE) de validación entre los modelos elegibles, es decir, aquellos cuyo puntaje de validación no estuvo contaminado por haber sido utilizado también para ajustar sus propios hiperparámetros; el conjunto de prueba nunca se utilizó para seleccionar.

Para la serie ALB, el modelo seleccionado fue un AutoARIMA ajustado automáticamente (MASE de validación de 0,475), apenas por debajo de la referencia estacional ingenua (0,489) y con una mejora relativa considerable frente al SARIMA refit del trabajo anterior (0,923). Sin embargo, en el conjunto de prueba el propio SARIMA del trabajo anterior resultó el más preciso de las 32 configuraciones evaluadas (MASE de 1,526, primer puesto), por delante de un Prophet ajustado con ventana libre de fuga de información (1,578) y del modelo seleccionado (2,058, duodécimo puesto), lo que revela una consistencia baja y no significativa entre validación y prueba para esta serie (correlación de Spearman $\rho = 0,237$, $p = 0,192$). Para la serie store-service, el modelo seleccionado fue la propia referencia estacional ingenua con período 24 (MASE de validación de 0,480): ningún modelo de Machine Learning, Deep Learning, híbrido o de fundación logró superarla de manera no contaminada en validación. No obstante, en el conjunto de prueba el mejor desempeño correspondió a NeuralProphet (MASE de 1,071, primer puesto), con un puntaje de validación apenas mediocre (decimocuarto puesto); el modelo seleccionado quedó en el décimo puesto de prueba (MASE de 1,443). La consistencia entre validación y prueba resultó, en este caso, moderada y significativa ($\rho = 0,654$, $p < 0,001$), aunque no evita divergencias puntuales como la de NeuralProphet. En síntesis, el enfoque clásico del trabajo anterior no fue superado de manera consistente por los modelos más recientes: los supera en la serie ALB en el conjunto de prueba, y en store-service es superado

solo por un modelo de la familia Prophet que la regla de selección honesta no habría elegido.

En la serie pública de contraste (Wikipedia en español), la referencia estacional ingenua fue seleccionada por validación (MASE de 0,438), pero en prueba el mejor modelo fue Ridge (MASE de 0,784) y el SARIMA del trabajo anterior resultó el de peor desempeño (MASE de 2,513), es decir, el desempeño relativo del SARIMA depende de la serie: fue el mejor en ALB y el peor en Wikipedia. Este contraste se obtuvo con una batería reducida y sin ajuste de hiperparámetros.

Las principales limitaciones del trabajo son la ventana única de validación de 48 horas, previa a una intervención de despliegue que debió imputarse; el historial todavía acotado (menos de tres meses); la presencia de modelos con puntaje de validación contaminado en el conjunto explorado, documentada pero no utilizada para seleccionar; y una posible anomalía en las últimas horas registradas de la serie store-service, no verificada como error de exportación de datos. Se concluye que, bajo un protocolo de validación estricto, la superioridad de los modelos de aprendizaje automático y profundo sobre el enfoque clásico del trabajo anterior no es uniforme: depende de la serie, del horizonte evaluado y del criterio de comparación utilizado.

Índice

Resumen ejecutivo	1
Introducción	7
Objetivos	7
Contextualización del problema	8
Descripción de las series seleccionadas	8
Organización del informe	9
Marco teórico	9
Modelos ingenuos y estadísticos clásicos	9
Machine Learning: árboles con boosting y ensambles	10
Deep Learning	10
Modelos híbridos y de descomposición	11
AutoML y modelos de fundación	11
Métricas de error y esquema de validación	11
Análisis de resultados	12
Preparación de datos y protocolo de evaluación	12
Adquisición y preprocesamiento	12
Variables utilizadas	13
Esquema de validación y horizonte de prueba	13
Resultados por familia de modelos	16
Referencias ingenuas y modelos estadísticos clásicos	16
Machine Learning: árboles con boosting y ensambles	16
Deep Learning	16
Prophet, modelos híbridos, AutoML y modelo de fundación	18
Comparación entre familias	19
Selección del modelo y consistencia entre validación y prueba	21
Costo computacional	22
Pronóstico final a 48 horas	22
Serie pública adicional: visitas horarias de Wikipedia en español	24
Conclusiones	26
Síntesis por serie	26
Consistencia entre validación y prueba	26
Serie pública de contraste	27
Límites del trabajo	27
Líneas de trabajo futuro	28

Declaración de uso de IA generativa	29
Referencias bibliográficas	30
Serie pública (Wikipedia en español): métricas completas	40

Índice de figuras

1.	Serie ALB sin procesar, con la rampa de encendido del balanceador previa al 3 de julio de 2026.	13
2.	Detalle de la intervención de despliegue (17 al 22 de septiembre de 2026) en ambas series.	14
3.	Nivel medio por día de la semana, ambas series, historial efectivo.	14
4.	Esquema de partición temporal en entrenamiento, validación y prueba.	15
5.	Importancia de variables (SHAP) del mejor modelo de Machine Learning, serie ALB.	17
6.	MASE de validación, modelos de Prophet, híbridos, AutoML y de fundación.	19
7.	Mejor MASE de validación por familia de modelos, ambas series.	19
8.	Dispersión entre el orden de validación y el orden de prueba, ambas series.	22
9.	Pronósticos sobre el conjunto de prueba: modelo seleccionado, peor modelo, SARIMA (TP1 refit) y Chronos, ambas series.	23
10.	Pronóstico final de 48 horas con intervalos de predicción, ambas series.	24
11.	Serie Wikipedia en español: MAE de prueba por modelo y pronóstico de los tres mejores sobre la ventana de prueba.	25
12.	Serie Wikipedia en español: últimos siete días observados y pronóstico final de 48 horas.	26
A1.	Descomposición MSTL (tendencia, estacionalidad diaria y semanal, residuo), serie ALB.	33
A2.	Descomposición MSTL, serie store-service.	34
A3.	Perfil horario por día de la semana (mapa de calor), serie ALB.	34
A4.	Perfil horario por día de la semana (mapa de calor), serie store-service.	35
A5.	Autocorrelación y autocorrelación parcial, serie ALB.	35
A6.	Autocorrelación y autocorrelación parcial, serie store-service.	36
A7.	Correlación cruzada entre ALB y store-service (serie transformada), rezagos de -24 a 24 horas.	36
A8.	Importancia de variables (SHAP) del mejor modelo de Machine Learning, serie store-service.	37
A9.	MASE de validación, modelos de Machine Learning (fase 03), ambas series.	37
A10.	MAPE de validación, referencias ingenuas y modelos clásicos (fase 02), ambas series.	38
A11.	Pronóstico de prueba de los mejores modelos de la fase 02, ambas series.	38
A12.	Pronóstico de prueba del mejor modelo de la fase 05 (Prophet, híbridos, AutoML y fundación), ambas series.	39

Índice de tablas

1.	Ventanas del protocolo de evaluación (todos los horarios en UTC).	14
2.	MASE de validación antes y después de la corrección de pesos, por arquitectura de Deep Learning.	17

3.	Mejor época (de un máximo de 100, paciencia 12) por arquitectura, serie y semilla. .	18
4.	Comparación compacta de modelos – serie ALB (MAE en unidades de la serie; MASE adimensional).	20
5.	Comparación compacta de modelos – serie store-service.	20
6.	Análisis de sensibilidad del criterio de selección (no constituye una regla de selección alternativa).	22
7.	Tiempo de ajuste de los modelos de mayor costo computacional (segundos).	23
8.	Comparación de modelos – serie Wikipedia en español (MAE en visitas por hora; MASE adimensional).	25
A1.	Conjunto completo de 32 configuraciones evaluadas – serie ALB.	32
A2.	Conjunto completo de 32 configuraciones evaluadas – serie store-service.	32
B1.	Métricas completas de los seis modelos – serie Wikipedia en español.	40

Introducción

Una de las tareas centrales del analista de datos consiste en articular los fundamentos teóricos de la modelización basada en datos con la implementación práctica de algoritmos capaces de anticipar el comportamiento futuro de un fenómeno observado en el tiempo. El presente trabajo retoma dos de las series temporales analizadas en el Trabajo Práctico N.º 1 de la materia Análisis de Series Temporales de la Maestría en Ciencia de Datos de la Universidad Austral e incorpora, sobre ese mismo dominio, un conjunto ampliado de técnicas de Machine Learning, Deep Learning, modelos híbridos, AutoML y modelos de fundación, con el propósito de contrastar su desempeño contra el de los modelos clásicos empleados previamente.

Objetivos

Objetivo general. Determinar si los modelos contemporáneos de aprendizaje automático y profundo mejoran, bajo un protocolo de validación honesto y sin fuga de información, el pronóstico obtenido con modelos estadísticos clásicos sobre series horarias de tráfico de infraestructura productiva.

Objetivos específicos.

- Extender el historial disponible de las series estudiadas en el trabajo anterior e incorporar una intervención de despliegue ocurrida durante el período ampliado.
- Implementar y comparar un conjunto representativo de modelos, organizado en las siguientes familias:
 - modelos ingenuos y estadísticos clásicos, incluida la reestimación del SARIMA del trabajo anterior;
 - modelos de Machine Learning basados en árboles con boosting y ensambles;
 - modelos de Deep Learning (redes recurrentes, convolucionales y basadas en atención);
 - modelos híbridos de descomposición estacional, Prophet y NeuralProphet;
 - plataformas de AutoML para series temporales;
 - un modelo de fundación de series temporales preentrenado (Chronos).
- Establecer una regla de selección de modelo por serie que no utilice el conjunto de prueba y que documente explícitamente los puntajes de validación contaminados por fuga de información.
- Pronosticar, con el modelo seleccionado en cada serie, una ventana de 48 horas posteriores al final del historial disponible, con sus respectivos intervalos de predicción.
- Contrastar la consistencia entre el desempeño en validación y en prueba, y discutir honestamente los límites de esa consistencia.

Contextualización del problema

Las dos series estudiadas provienen de la infraestructura productiva de BodegaAI y miden, con periodicidad horaria, la carga de solicitudes que atraviesa dos capas distintas de un mismo sistema: el balanceador de carga de borde (serie ALB, *RequestCount* total) y un servicio interno de tienda, medido por destino de balanceo (*RequestCountPerTarget*, serie store-service). Ambas series constituyen, en la práctica, la principal señal de capacidad utilizada para decisiones de escalado automático y de planificación operativa; un pronóstico de corto plazo confiable permite anticipar períodos de alta demanda y detectar desvíos respecto del comportamiento esperado. A diferencia del Trabajo Práctico N.º 1, donde el historial disponible cubría un mes y la segunda serie correspondía a un servicio distinto (interfaz de punto de venta), el presente trabajo dispone de aproximadamente tres meses de historial para ambas series y debe además tratar una intervención real: una reversión de despliegue (*rollback*) que redujo transitoriamente el tráfico observado. El tratamiento de esa intervención como un evento a imputar, y no como una observación válida del proceso, sigue la lógica del análisis de intervención propuesto por Box y Tiao (1975).

Descripción de las series seleccionadas

En primer lugar, la serie ALB registra la cantidad total de solicitudes por hora atendidas por el balanceador de carga de producción desde el 1 de mayo de 2026 (BodegaAI, 2026a). El balanceador entró en operación real hacia el 26 de junio de 2026; antes de esa fecha, y durante una rampa de encendido de aproximadamente una semana, el tráfico registrado no representa el régimen estable del sistema y se descarta del análisis. A partir del 3 de julio de 2026 la serie alcanza un nivel estable, con estacionalidad diaria marcada (fuerza estacional de 0,771 sobre un período de 24 horas, según la descomposición MSTL) y una estacionalidad semanal comparativamente débil (fuerza de 0,206 sobre un período de 168 horas).

En segundo lugar, la serie store-service registra, con la misma periodicidad horaria y desde la misma fecha de origen, la cantidad de solicitudes por destino de balanceo del servicio interno de tienda (BodegaAI, 2026b). Esta serie exhibe una estacionalidad diaria aún más marcada que la serie ALB (fuerza estacional de 0,846) y una correlación cruzada prácticamente contemporánea con ella ($r = 0,852$ en rezago cero, sin evidencia de una relación de adelanto-atraso aprovechable como variable exógena). Ambas series comparten, además, el mismo evento de intervención: entre el 17 de septiembre de 2026 a las 18:00 UTC y el 22 de septiembre de 2026 a las 13:00 UTC se produjo una reversión de despliegue que redujo el tráfico de ALB a aproximadamente el 72 % del nivel de la semana anterior, y el de store-service a un rango de entre el 80 % y el 90 %; tras la reversión, store-service se estabiliza alrededor de un 7 % por debajo de su nivel previo, atribuible a un cambio en la cantidad de destinos de balanceo activos y no a un artefacto de los datos.

En tercer lugar, se incorpora una serie pública e independiente de BodegaAI: la cantidad de visitas por hora de usuarios a la edición en español de Wikipedia (proyecto *es.wikipedia*, acceso *all-access*, agente *user*, es decir, tráfico de usuarios sin *bots* declarados), obtenida de la interfaz de métricas de páginas vistas de la Fundación Wikimedia (Wikimedia Foundation, 2026), cuyos

conjuntos de datos analíticos se publican bajo la dedicación CC0. Su elección obedece a cuatro motivos: mide el mismo tipo de fenómeno que las series anteriores (volumen horario de solicitudes web generado por personas); cubre exactamente el mismo calendario (2.063 observaciones horarias entre el 3 de julio y el 26 de septiembre de 2026, sin huecos), lo que permite aplicar sin cambios el protocolo de validación y de prueba; es de acceso abierto y reproducible; y aporta un contraste de dominio, dado que se trata de tráfico externo, no afectado por el despliegue y la reversión que alteraron a las series de BodegaAI. La serie presenta un ciclo diario marcado y una autocorrelación semanal alta (0,958 en el rezago de 24 horas y 0,956 en el de 168 horas sobre el logaritmo de la serie, frente a 0,838 y 0,614 en ALB). Su relación con las series de BodegaAI es de contexto y no de dependencia: la correlación de los niveles logarítmicos es de 0,41 con ALB y de 0,49 con store-service, pero la de los cambios a 24 horas es prácticamente nula ($-0,01$ y $0,01$), por lo que no se espera valor predictivo cruzado. Por restricciones de tiempo, esta serie se trata como un contraste acotado (Sección) y no con la batería completa de 32 configuraciones.

Organización del informe

El resto del informe se organiza de la siguiente manera. La sección de Marco Teórico presenta, de forma sintética, los fundamentos de cada familia de modelos empleada y las métricas de error utilizadas para compararlos. La sección de Análisis de Resultados describe la preparación de los datos, el protocolo de validación y evaluación, y los resultados obtenidos por familia de modelos para cada serie, incluida la regla de selección del modelo final y el pronóstico de 48 horas resultante. Las Conclusiones sintetizan los hallazgos por serie, discuten las limitaciones del trabajo y proponen líneas de continuación. Los Apéndices reúnen las tablas completas de las 32 configuraciones evaluadas por serie y los fragmentos de código más extensos.

Marco teórico

Esta sección presenta, de manera sintética, los fundamentos de cada familia de modelos utilizada en el trabajo y las métricas empleadas para evaluarlos. Dado el volumen de técnicas comparadas, se prioriza una descripción breve del mecanismo de cada modelo y de su cita de origen, remitiendo a la sección de Análisis de Resultados para el detalle de los hiperparámetros efectivamente explorados.

Modelos ingenuos y estadísticos clásicos

Las referencias ingenuas (*naive*, *seasonal naive*, *drift* y *average*) constituyen el piso mínimo de comparación exigido en cualquier ejercicio de pronóstico (Hyndman & Athanasopoulos, 2021). La referencia estacional ingenua con período $m = 24$, en particular, replica el último valor observado en la misma hora del día anterior y resulta especialmente difícil de superar en series con estacionalidad diaria fuerte, como las estudiadas en este trabajo.

Los modelos ARIMA y su extensión estacional SARIMA combinan componentes autorregresivos, de promedio móvil y de diferenciación para representar series no estacionarias con estructura de dependencia temporal (Box et al., 2015). La condición de estacionariedad que estos modelos

presuponen se evalúa, en este trabajo, mediante los contrastes de Dickey-Fuller aumentado (Dickey & Fuller, 1979) y de Kwiatkowski-Phillips-Schmidt-Shin (Kwiatkowski et al., 1992), mientras que la adecuación del ajuste sobre los residuos se verifica con el estadístico de Ljung-Box (Ljung & Box, 1978). El SARIMA ajustado en el Trabajo Práctico N.º 1 se reutiliza en este trabajo como modelo fundacional, reajustado (*refit*) sobre el historial ampliado, con el fin de aislar el efecto de la extensión de datos del efecto de la técnica de modelado. El suavizado exponencial de Holt-Winters y la descomposición estacional robusta MSTL –que permite múltiples períodos estacionales simultáneos y admite un modelo autorregresivo sobre la tendencia extraída– completan el conjunto de técnicas clásicas (Hyndman & Athanasopoulos, 2021), ambas implementadas sobre la librería Statsmodels (Seabold & Perktold, 2010). La selección automática de orden mediante AutoARIMA, finalmente, recorre un espacio de modelos ARIMA/SARIMA y selecciona el de menor criterio de información, evitando la identificación manual basada en autocorrelación.

Machine Learning: árboles con boosting y ensambles

Los métodos de *gradient boosting* sobre árboles de decisión ajustan de manera secuencial modelos débiles que corrigen los errores residuales de la etapa anterior (Friedman, 2001). Este trabajo compara tres implementaciones de uso extendido en la industria: LightGBM, que introduce muestreo por gradiente y agrupamiento exclusivo de variables para acelerar el entrenamiento en conjuntos de datos grandes (Ke et al., 2017); XGBoost, que formaliza una función objetivo regularizada y una estrategia eficiente de búsqueda de particiones (Chen & Guestrin, 2016); y CatBoost, que introduce un esquema de *ordered boosting* para reducir el sesgo de las variables categóricas y del propio proceso de boosting (Prokhorenkova et al., 2018). Como referencia de ensamble no secuencial se incluye Random Forest, que promedia árboles entrenados sobre submuestras aleatorias del conjunto de entrenamiento y de las variables (Breiman, 2001), y Ridge, una regresión lineal regularizada utilizada como línea de base simple dentro de la familia de Machine Learning. Todos estos modelos se alimentan con variables de rezago, estadísticos móviles y variables de calendario, generadas y encadenadas recursivamente mediante la librería skforecast (Amat Rodrigo & Escobar Ortiz, 2024). Como estrategia de combinación adicional se evalúa un *stacking* de los tres mejores modelos de esta familia, siguiendo el principio de generalización apilada de Wolpert (1992): un metamodelo aprende a combinar las predicciones de los modelos base a partir de una validación interna.

Deep Learning

Las redes neuronales recurrentes de tipo memoria de largo-corto plazo (LSTM) incorporan compuertas que regulan el flujo de información a lo largo de la secuencia, mitigando el desvanecimiento del gradiente que afecta a las redes recurrentes simples (Hochreiter & Schmidhuber, 1997). N-BEATS propone, en cambio, una arquitectura totalmente conectada, sin componentes recurrentes ni convolucionales, organizada en bloques residuales que expanden una base interpretable de tendencia y estacionalidad (Oreshkin et al., 2020). N-HiTS extiende esa idea con muestreo jerárquico multitasa y una interpolación multiescala orientada a abaratar el costo computacional en

horizontes largos (Challu et al., 2023). Las redes convolucionales temporales (TCN) aplican convoluciones causales y dilatadas para capturar dependencias de largo alcance sin recurrencia (Bai et al., 2018). TiDE combina un codificador denso con conexiones residuales para lograr un costo de entrenamiento reducido frente a arquitecturas basadas en atención, con desempeño competitivo (Das et al., 2023). Finalmente, el Transformer de fusión temporal (TFT) incorpora mecanismos de atención multihorizonte y selección de variables interpretable, a costa de un tiempo de entrenamiento sensiblemente mayor (Lim et al., 2021). Las seis arquitecturas se implementaron mediante la librería Darts (Herzen et al., 2022).

Modelos híbridos y de descomposición

Prophet formula la serie como una suma de componentes de tendencia, estacionalidad y efectos de calendario, ajustados mediante un modelo aditivo generalizado con una interfaz orientada a la producción a escala (Taylor & Letham, 2018). NeuralProphet retoma esa misma descomposición interpretable pero la implementa dentro de una red neuronal entrenada por descenso de gradiente, lo que permite incorporar autorregresión no lineal sobre los rezagos (Triebe et al., 2021). Como estrategia híbrida adicional se evalúa una descomposición MSTL seguida de un modelo LightGBM sobre la serie desestacionalizada, que combina la interpretabilidad de la descomposición clásica con la capacidad no lineal de un modelo de árboles (Hyndman & Athanasopoulos, 2021; Ke et al., 2017).

AutoML y modelos de fundación

AutoGluon TimeSeries automatiza la selección y el ensamblado ponderado de un conjunto amplio de modelos candidatos, sin intervención manual sobre los hiperparámetros (Shchur et al., 2023). AutoTS sigue un enfoque análogo, con generaciones evolutivas de combinaciones de modelos sobre una plantilla acotada de técnicas rápidas. Ambas plataformas se contrastan además con Chronos, un modelo de fundación de series temporales preentrenado sobre un corpus masivo y heterogéneo de series, evaluado en este trabajo en modalidad de inferencia directa (*zero-shot*), sin ajuste alguno sobre las series propias (Ansari et al., 2024). Los modelos estadísticos clásicos y de AutoARIMA se implementaron mediante la librería StatsForecast (Garza et al., 2022).

Métricas de error y esquema de validación

El error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE) expresan el error en las unidades originales de la serie, mientras que el error porcentual absoluto medio (MAPE) lo expresa en términos relativos. Ninguna de estas tres métricas, sin embargo, permite comparar el desempeño entre series de escalas distintas ni distinguir un buen pronóstico de uno que simplemente aprovecha una estacionalidad fuerte. El error absoluto escalado medio (MASE) resuelve ambas limitaciones al normalizar el error absoluto del modelo por el error absoluto, dentro de la muestra de entrenamiento, de una referencia estacional ingenua de período m (Hyndman & Koehler, 2006); un MASE menor a 1 indica que el modelo supera a esa referencia. Este trabajo adopta $m = 24$

para ambas series, dado que la estacionalidad semanal resultó comparativamente débil (sección de Análisis de Resultados), y utiliza el MASE de validación como criterio único de selección del modelo final.

El protocolo de validación empleado consiste en una única ventana de contraste de 48 horas, inmediatamente anterior al inicio de la intervención de despliegue, y un conjunto de prueba de 105 horas posterior a su finalización. Esta elección –una sola ventana en lugar de una validación cruzada expandida de múltiples pliegues– prioriza mantener acotado el tiempo total de cómputo frente a un conjunto de aproximadamente quince familias de modelos, a costa de una estimación del error de generalización más ruidosa; esta limitación se retoma en las Conclusiones. Para evitar la fuga de información, el ajuste de hiperparámetros y la parada anticipada de las redes profundas se realizan sobre una ventana de 168 horas anterior al historial de entrenamiento, distinta de la ventana de validación utilizada para clasificar y seleccionar los modelos.

Análisis de resultados


Preparación de datos y protocolo de evaluación

Adquisición y preprocesamiento

Ambas series se registran con periodicidad horaria desde el 1 de mayo de 2026. El balanceador de carga entró en operación real hacia el 26 de junio de 2026; los valores previos son nulos o corresponden a una rampa de encendido de aproximadamente una semana, en la que el tráfico crece de forma sostenida hasta alcanzar un nivel estable (Figura 1). Este período se descarta y el historial efectivo de trabajo queda acotado entre el 3 de julio de 2026, 00:00 UTC, y el 26 de septiembre de 2026, 22:00 UTC: 2.063 observaciones horarias por serie, sin valores faltantes ni ceros, con frecuencia horaria estrictamente monótona.

Sobre la serie transformada (logaritmo más uno), los contrastes de Dickey-Fuller aumentado (Dickey & Fuller, 1979) y de Kwiatkowski-Phillips-Schmidt-Shin (Kwiatkowski et al., 1992) coinciden en rechazar la estacionariedad en niveles para ambas series (ALB: $p_{ADF} = 0,810$, $p_{KPSS} = 0,010$; store-service: $p_{ADF} = 0,174$, $p_{KPSS} = 0,010$) y en no rechazarla tras una primera diferencia (ALB: $p_{ADF} \approx 0,000$, $p_{KPSS} = 0,100$; store-service: $p_{ADF} \approx 0,000$, $p_{KPSS} = 0,100$), lo que justifica el orden de diferenciación de los modelos ARIMA/SARIMA empleados.

Entre el 17 de septiembre de 2026, 18:00 UTC, y el 22 de septiembre de 2026, 13:00 UTC (116 horas), una reversión de despliegue redujo transitoriamente el tráfico observado (Figura 2). Siguiendo el tratamiento de eventos exógenos propuesto por Box y Tiao (1975), esta ventana no se descarta ni se trata como una observación válida del proceso: se imputa reemplazando cada hora por el valor observado en la misma hora de la semana anterior, corregido por un factor de nivel que preserva el crecimiento orgánico semana a semana (razón entre el promedio de las 168 horas previas a la intervención y el promedio de las 168 horas de la semana anterior a esas). Tras la reversión, la serie store-service se estabiliza en un nivel aproximadamente 7 % por debajo del previo a la intervención, atribuible a un cambio en la cantidad de destinos de balanceo activos; este

**Figura 1**

Serie ALB sin procesar, con la rampa de encendido del balanceador previa al 3 de julio de 2026.

desplazamiento se trata como parte del proceso genuino y no se corrige.

Variables utilizadas

Los modelos de Machine Learning se alimentan con rezagos de 1 a 24, 48, 168 y 336 horas, estadísticos móviles (media y desvío) en ventanas de 24 y 168 horas, y variables de calendario (hora local, día de la semana, fin de semana, feriado argentino, indicador de intervención). La correlación cruzada entre ambas series, calculada sobre la serie transformada (logaritmo más uno y primera diferencia), alcanza su máximo en el rezago cero ($r = 0,852$; Apéndice A), sin evidencia de una relación de adelanto-atraso aprovechable; por esa razón, ninguna serie se utiliza como variable exógena de la otra. La estacionalidad semanal, con medias por día de la semana que difieren menos del 3 % respecto de la media general en ambas series (Figura 3), se considera despreciable frente a la estacionalidad diaria (fuerza estacional de 0,771 para ALB y 0,846 para store-service, según la descomposición MSTL) y se excluye de los modelos Prophet, NeuralProphet y del período estacional utilizado por el MASE ($m = 24$).

Esquema de validación y horizonte de prueba

A diferencia de una validación cruzada expandida de múltiples pliegues, este trabajo adopta una única ventana de validación de 48 horas (Figura 4), decisión justificada por el tiempo total de cómputo que exige comparar 32 configuraciones por serie. La Tabla 1 resume las ventanas del protocolo.

Para evitar la fuga de información señalada en la sección de Marco Teórico, el ajuste de hi-




Figura 2

Detalle de la intervención de despliegue (17 al 22 de septiembre de 2026) en ambas series.





Figura 3

Nivel medio por día de la semana, ambas series, historial efectivo.

Tabla 1

Ventanas del protocolo de evaluación (todos los horarios en UTC).

Segmento	Rango	Extensión
Historial efectivo	03/07/2026 00:00 – 26/09/2026 22:00	2.063 h
Ajuste seguro (tuning / <i>early stopping</i>)	168 h previas a la ventana de validación	168 h
Validación (selección del modelo)	48 h previas al inicio de la intervención	48 h
Intervención (imputada)	17/09/2026 18:00 – 22/09/2026 13:00	116 h
Prueba	22/09/2026 14:00 – 26/09/2026 22:00	105 h
Pronóstico final	26/09/2026 23:00 – 28/09/2026 22:00	48 h

**Figura 4**

Esquema de partición temporal en entrenamiento, validación y prueba.

perparámetros de los modelos de Machine Learning y la parada anticipada de las redes profundas se realizan exclusivamente sobre la ventana de 168 horas previa a la ventana de validación, nunca sobre esta última. El Código 1 ilustra esta separación para las arquitecturas de Deep Learning, junto con la restitución de los pesos de la mejor época tras la parada anticipada –una corrección aplicada durante el desarrollo del trabajo, que se documenta más adelante, al tratar los modelos de Deep Learning–.

```
fit_part = train.iloc[:-ES_WINDOW_HOURS]          # 168 h reservadas
val_part = train.iloc[-(INPUT_CHUNK_LENGTH + ES_WINDOW_HOURS):]

tracker = _BestEpochTracker()
model = self._build(
    n_epochs=MAX_EPOCHS,
    callbacks=[EarlyStopping(monitor="val_loss", patience=PATIENCE, mode="min"),
               tracker],
)
model.fit(series=fit_ts, val_series=val_ts, verbose=False)
if tracker.best_state is not None:
    model.model.load_state_dict(tracker.best_state) # no se usan los pesos post-
                                                    paciencia
```

Código 1: Ajuste con ventana libre de fuga de información y restitución de la mejor época (tsa_final/dl_models.py).

Resultados por familia de modelos

Referencias ingenuas y modelos estadísticos clásicos

Las cuatro referencias ingenuas y los cuatro modelos clásicos (Holt-Winters, MSTL con AutoARIMA sobre la tendencia, AutoARIMA y el SARIMA refit del Trabajo Práctico N.º 1) constituyen el primer nivel de comparación. En validación, la referencia estacional ingenua ($m = 24$) ya resulta muy difícil de superar: MASE de 0,489 en ALB y de 0,480 en store-service. El AutoARIMA la supera levemente en ALB (0,475) y queda apenas por encima en store-service (0,532). El SARIMA refit del trabajo anterior, en cambio, obtiene un MASE de validación considerablemente peor en ambas series (0,923 y 0,647, respectivamente): su orden fue identificado sobre datos de un mes y una rampa de tráfico distinta, y no se reoptimiza en este trabajo. Esa desventaja en validación se revierte por completo en el conjunto de prueba, como se discute más adelante, en la sección de selección del modelo.

Machine Learning: árboles con boosting y ensambles

Con hiperparámetros por defecto, ningún modelo de Machine Learning supera a la referencia estacional ingenua en validación: el mejor de ellos en ALB (CatBoost, MASE 0,598) y en store-service (Ridge, MASE 1,201) quedan por encima de 0,489 y 0,480, respectivamente. Solo tras ajustar hiperparámetros con Optuna –sobre la misma ventana de 48 horas luego utilizada para clasificar los modelos– tres configuraciones de ALB (CatBoost, Random Forest y LightGBM ajustados) logran un MASE de validación inferior a la referencia ingenua (0,353, 0,416 y 0,421, respectivamente); en store-service, ninguna configuración ajustada alcanza ese umbral (mínimo de 0,573 con LightGBM ajustado). Estos cinco modelos se marcan como *contaminados* en este trabajo, dado que su puntaje de validación es optimista por construcción: fueron optimizados sobre la misma ventana que luego los clasifica. El efecto es visible en el conjunto de prueba: CatBoost ajustado, el mejor de ALB en validación, cae al puesto 17 de 32 en prueba (MASE 2,313), y Random Forest ajustado resulta, dentro de esta familia, el de peor desempeño relativo en prueba dentro de la serie ALB (MASE 3,455, frente a 0,416 en validación). El *stacking* de los tres mejores modelos ajustados, por su parte, resulta el peor modelo de toda la familia de Machine Learning en ambas series y en ambos conjuntos (MASE de prueba de 4,989 en ALB y 1,981 en store-service), lo que sugiere que combinar modelos ya sobreajustados a la ventana de validación no mitiga, sino que propaga, ese sobreajuste. La Figura 5 muestra que los rezagos de 1, 2, 23, 24 y 48 horas dominan la importancia de las variables según SHAP, muy por delante de los rezagos semanales (168 horas), lo que es consistente con la estacionalidad diaria dominante documentada en la sección de preparación de datos.

Deep Learning

El desarrollo de las seis arquitecturas de Deep Learning reveló un defecto metodológico corregido antes de la selección final: el mecanismo de parada anticipada de la librería Darts conserva los pesos de la última época evaluada, no los de la época de menor error de validación, mientras que el ajuste final sobre prueba entrena exactamente la cantidad de épocas de la mejor época.




Figura 5

Importancia de variables (SHAP) del mejor modelo de Machine Learning, serie ALB.

La primera corrida comparaba, en consecuencia, un modelo sobreentrenado en validación contra un modelo correctamente detenido en prueba. La corrección –restituir explícitamente los pesos de la mejor época tras la parada anticipada, documentada en el Código 1– se aplicó a las 24 combinaciones de arquitectura, serie y semilla con parada anticipada, y modificó únicamente los puntajes de validación; los de prueba permanecen sin cambios, salvo en tres ajustes de TFT en los que el mecanismo de atención, no determinístico en GPU, produjo una mejor época distinta entre corridas. La Tabla 2 resume el efecto de la corrección sobre el MASE de validación promediado entre las dos semillas utilizadas.

Tabla 2

MASE de validación antes y después de la corrección de pesos, por arquitectura de Deep Learning.

Arquitectura	ALB		store-service	
	Antes	Corregido	Antes	Corregido
LSTM	2,337	1,909	1,017	0,728
N-BEATS	1,119	0,980	1,444	0,638
N-HiTS	0,875	0,556	1,097	0,689
TCN	2,323	1,153	0,760	0,732
TFT	1,516	1,535	1,342	1,083
TiDE	0,998	0,790	1,211	0,862

Se destaca en negrita el mejor MASE corregido de cada serie (N-HiTS en ALB, N-BEATS en store-service).

Ninguna arquitectura de Deep Learning supera a la referencia estacional ingenua en validación

tras la corrección, aunque la distancia se reduce sustancialmente respecto de la primera corrida (por ejemplo, N-HiTS pasa de 0,875 a 0,556 en ALB). En el conjunto de prueba, N-BEATS resulta el mejor modelo de Deep Learning en ambas series (MASE de 1,744 en ALB y 1,247 en store-service), aunque no el mejor modelo del proyecto completo (sección de selección del modelo, más adelante). El caso más notorio es el de LSTM en ALB: la mejor época, para ambas semillas, es la primera (Tabla 3), un resultado reproducido de forma idéntica antes y después de la corrección y que se interpreta como un hallazgo genuino –el modelo prácticamente no llega a entrenarse antes de que la pérdida de validación comience a degradarse– y no como un artefacto de implementación; en prueba, esta arquitectura resulta el peor modelo de las 32 configuraciones evaluadas para ALB (MASE de 7,817, último puesto). El Transformer de fusión temporal (TFT), por su parte, nunca ocupa el primer puesto en ninguna serie ni conjunto, pese a exigir el mayor costo de entrenamiento de todo el proyecto (sección de costo computacional, más adelante).

Tabla 3

Mejor época (de un máximo de 100, paciencia 12) por arquitectura, serie y semilla.

Arquitectura	Serie	Semilla 42	Semilla 43
LSTM	ALB	1	1
N-BEATS	ALB	83	97
N-HiTS	ALB	21	42
LSTM	store-service	18	17
N-BEATS	store-service	34	45

Prophet, modelos híbridos, AutoML y modelo de fundación

La Figura 6 presenta el MASE de validación de las ocho configuraciones de esta fase. El ensamble de ponderación uniforme (*equal-weight*, contaminado por construcción, ya que sus miembros se eligen con el mismo MASE de validación que este puntaje mide) encabeza la clasificación de ALB (0,404) y prácticamente iguala a la referencia ingenua en store-service (0,480126 frente a 0,480171). Entre los modelos no contaminados, Prophet sin ajuste de hiperparámetros resulta el más competitivo de la fase en ambas series (0,532 y 0,506, respectivamente), mientras que AutoGluon TimeSeries se aproxima en ALB (0,499). El híbrido de descomposición MSTL seguido de LightGBM sobre la serie desestacionalizada constituye el fracaso más marcado de esta fase: en store-service alcanza el peor MASE de validación de las ocho configuraciones (1,848) y, en prueba, el peor resultado de las 32 configuraciones evaluadas para esa serie (MASE de 3,100, último puesto de 32); en ALB su MASE de prueba (5,721) también es de los más altos del proyecto (puesto 30 de 32). Este comportamiento es consistente con una deriva recursiva: al reconstruir la componente estacional futura repitiendo los últimos 24 valores observados, cualquier error del componente LightGBM sobre la tendencia se acumula sin corrección a lo largo del horizonte de prueba.

Chronos, evaluado en modalidad de inferencia directa sin ajuste alguno sobre las series propias, obtiene un MASE de validación intermedio en ambas series (0,598 en ALB, 0,816 en store-service), un resultado razonable para un modelo que nunca observó estas series durante su preentrenamiento.




Figura 6

MASE de validación, modelos de Prophet, híbridos, AutoML y de fundación.

Su intervalo de predicción, sin embargo, solo cubre los cuantiles 0,1 y 0,9 sobre los que fue entrenado: el intervalo del 95 % se deja explícitamente sin definir en el pronóstico final, en lugar de aproximarlo con un cuantil para el que el modelo no fue entrenado.

Comparación entre familias

La Figura 7 resume el mejor MASE de validación logrado por cada familia de modelos, en ambas series. Las Tablas 4 y 5 presentan, de forma compacta, el mejor modelo de cada familia junto con el modelo seleccionado, el peor modelo elegible, el SARIMA refit del trabajo anterior y Chronos; las 32 configuraciones completas de cada serie se listan en el Apéndice A.




Figura 7

Mejor MASE de validación por familia de modelos, ambas series.

Tabla 4

Comparación compacta de modelos – serie ALB (MAE en unidades de la serie; MASE adimensional).

Modelo	Familia	MAE val.	MASE val.	MASE prueba
auto_arima (seleccionado)	Clásico	18.807,50	0,475	2,058
seasonal_naive_m24	Ingenuo	19.369,02	0,489	1,990
SARIMA (TP1 refit)	Fundacional TP1	36.524,57	0,923	1,526
catboost_tuned ^a	ML	13.994,36	0,353	2,313
catboost_direct	ML (directo)	21.126,48	0,534	2,364
nhits	DL	22.021,71	0,556	2,441
prophet_default	Prophet	21.066,96	0,532	2,065
mstl_lightgbm	Híbrido	28.341,14	0,716	5,721
autogluon_timeseries	AutoML	19.748,53	0,499	1,974
chronos_bolt_base	Fundación	23.678,74	0,598	2,007
ensemble_equal_weight ^a	Ensamble	16.006,29	0,404	2,352
average	Peor elegible	149.950,95	3,788	6,011

^aPuntaje de validación contaminado; no elegible para la selección.

Tabla 5

Comparación compacta de modelos – serie store-service.

Modelo	Familia	MAE val.	MASE val.	MASE prueba
seasonal_naive_m24 (seleccionado)	Ingenuo	2.281,85	0,480	1,443
auto_arima	Clásico	2.525,88	0,532	1,408
SARIMA (TP1 refit)	Fundacional TP1	3.075,43	0,647	1,426
lightgbm_tuned ^a	ML	2.723,67	0,573	1,770
ridge_direct	ML (directo)	2.905,15	0,611	1,840
nbeats	DL	3.031,39	0,638	1,247
prophet_default	Prophet	2.405,88	0,506	1,083
neuralprophet	Prophet	3.297,54	0,694	1,071
mstl_lightgbm	Híbrido	8.779,73	1,848	3,100
autots	AutoML	2.412,97	0,508	1,596
chronos_bolt_base	Fundación	3.877,73	0,816	1,673
ensemble_equal_weight ^a	Ensamble	2.281,64	0,480	1,612
drift	Peor elegible	17.022,66	3,582	2,587

^aPuntaje de validación contaminado; no elegible para la selección. Se incluye NeuralProphet además del mejor Prophet por ser, con amplio margen, el mejor modelo de prueba de toda la serie (ver la sección siguiente, de selección del modelo).

Selección del modelo y consistencia entre validación y prueba

La regla de selección adoptada (Código 2) recorre el conjunto de 32 modelos por serie, descarta los marcados como contaminados y selecciona el de menor MAE de validación entre los restantes. Se marcan como contaminados los cinco modelos ajustados con Optuna sobre la ventana de validación en cada serie (`catboost_tuned`, `random_forest_tuned` y `lightgbm_tuned` en ALB; `ridge_tuned`, `lightgbm_tuned` y `xgboost_tuned` en store-service), el *stacking* construido a partir de esos modelos ajustados, y el ensamble de ponderación uniforme, cuyos miembros se eligen con el propio MAE de validación. Prophet ajustado (`prophet_tuned`) se excluye de esta lista porque su ajuste se realiza sobre la ventana segura de 168 horas descrita en la sección de preparación de datos, nunca sobre la ventana de validación.

```
def select_model(pool: pd.DataFrame, series: str) -> SelectionResult:
    """El modelo seleccionado es el de menor MAE de validacion entre los
    elegibles (la regla adoptada). El conjunto de prueba nunca se usa para
    seleccionar."""
    elig = eligible_val(pool, series)
    return SelectionResult(series=series, selected=elig.iloc[0],
                           runner_up=elig.iloc[1], worst=elig.iloc[-1])
```

Código 2: Regla de selección: menor MAE de validación entre los modelos elegibles (`tsa_final/selection.py`).

Bajo esta regla, el modelo seleccionado para ALB es `auto_arima` y para store-service es la propia referencia estacional ingenua. La comparación contra el SARIMA refit del trabajo anterior arroja una mejora del 48,5 % en validación para ALB (MASE de 0,475 frente a 0,923) y del 25,8 % en validación para store-service (0,480 frente a 0,647); en ambos casos, esa ventaja se revierte en el conjunto de prueba: el modelo seleccionado resulta un 34,9 % peor que el SARIMA refit en ALB y un 1,2 % peor en store-service. Comparado contra la referencia estacional ingenua, el modelo seleccionado de ALB mejora un 2,9 % en validación pero empeora un 3,4 % en prueba.

La Figura 8 y el coeficiente de correlación de Spearman entre el orden de validación y el orden de prueba cuantifican esta divergencia: para ALB, considerando las 32 configuraciones, $\rho = 0,237$ ($p = 0,192$), no significativo al 5 %; restringido a los 27 modelos elegibles, $\rho = 0,346$ ($p = 0,077$), tampoco significativo. Para store-service, en cambio, la consistencia es moderada y estadísticamente significativa: $\rho = 0,654$ ($p < 0,001$) sobre las 32 configuraciones, y $\rho = 0,692$ ($p < 0,001$) sobre las 27 elegibles. Esta significancia agregada, sin embargo, no impide divergencias puntuales severas: NeuralProphet, decimocuarto en validación de store-service, resulta el mejor modelo de prueba de toda la serie.

La Tabla 6 contrasta la regla adoptada con dos criterios alternativos, a título exclusivamente informativo: el que se obtendría si se permitieran modelos contaminados, y el que seleccionaría un oráculo que conociera de antemano el MAE de prueba –un criterio inaplicable en la práctica, dado que el pronóstico se produce antes de observar el conjunto de prueba–. Cada criterio elige un ganador distinto en ambas series, lo que evidencia que la elección del criterio de selección no es un




Figura 8

Dispersión entre el orden de validación y el orden de prueba, ambas series.

detalle menor del protocolo.

Tabla 6

Análisis de sensibilidad del criterio de selección (no constituye una regla de selección alternativa).

Criterio	Serie ALB	Serie store-service
Regla adoptada (MAE val., elegibles)	auto_arima	seasonal_naive_m24
Incluyendo modelos contaminados	catboost_tuned	ensemble_equal_weight
Oráculo de MAE de prueba ^a	SARIMA (TP1 refit)	neuralprophet

^aNo utilizable al momento de pronosticar; se incluye solo como referencia de contexto.

Costo computacional

El costo de ajuste no fue el criterio de selección, pero resulta relevante para evaluar la viabilidad operativa de cada familia. La Tabla 7 contrasta los modelos de mayor costo con el modelo seleccionado. El Transformer de fusión temporal (TFT) exige, por lejos, el mayor tiempo de ajuste del proyecto (entre 175 y 292 segundos por serie y conjunto, sumado sobre las dos semillas utilizadas), sin alcanzar el primer puesto en ninguna comparación; AutoGluon TimeSeries exhibe un costo fijo similar, producto de su límite de tiempo configurado (300 segundos por llamada), independientemente del tamaño de la serie.

Pronóstico final a 48 horas


Con el modelo seleccionado por serie reajustado sobre la totalidad del historial disponible (entrenamiento más validación, con la intervención imputada), se produce un pronóstico de 48 horas posteriores al final del historial, entre el 26 de septiembre de 2026 a las 23:00 UTC y el 28 de septiembre de 2026 a las 22:00 UTC. La Figura 9 contrasta, sobre el conjunto de prueba, las tra-

Tabla 7

Tiempo de ajuste de los modelos de mayor costo computacional (segundos).


Modelo	Serie	Ajuste (val.)	Reajuste (prueba)
TFT	ALB	292,41	195,67
TFT	store-service	271,62	175,47
AutoGluon TimeSeries	ALB	161,81	140,03
AutoGluon TimeSeries	store-service	119,65	147,21
auto_arima	ALB (seleccionado)	97,52	78,93
auto_arima	store-service	79,47	46,09
seasonal_naive_m24	ambas (seleccionado en store-service)	< 0,001	< 0,001

vectorias del modelo seleccionado, del peor modelo elegible, del SARIMA refit del trabajo anterior y de Chronos, contra el valor observado; la Figura 10 muestra el pronóstico de 48 horas propiamente dicho, con sus intervalos de predicción.

**Figura 9**

Pronósticos sobre el conjunto de prueba: modelo seleccionado, peor modelo, SARIMA (TP1 refit) y Chronos, ambas series.

Los intervalos de predicción provienen de fuentes distintas según el modelo: AutoARIMA y SARIMA aportan intervalos nativos de 80 % y 95 %; la referencia estacional ingenua y el peor modelo elegible utilizan intervalos empíricos, contruidos a partir de los residuos agrupados de la ventana de validación de 48 horas, y por lo tanto constantes en cada hora del horizonte; Chronos aporta únicamente el intervalo del 80 %, dado que fue entrenado solo sobre los cuantiles 0,1 y 0,9,

**Figura 10**

Pronóstico final de 48 horas con intervalos de predicción, ambas series.

y su intervalo del 95 % se deja sin definir en lugar de aproximarse con un cuantil no entrenado.

Serie pública adicional: visitas horarias de Wikipedia en español

Esta subsección presenta un contraste acotado sobre la serie pública descrita en la introducción. Se aplica el protocolo de la fase de evaluación (ventana de validación de 48 horas, ventana de prueba de 105 horas y MASE con período 24) y se evalúan seis modelos con hiperparámetros por defecto: la referencia estacional ingenua, Holt-Winters, el SARIMA(1, 1, 1) × (1, 1, 1)₂₄ del trabajo anterior, Ridge y LightGBM (recursivos, con rezagos de hasta 336 horas y variables de calendario) y Prophet. No se incluyeron Deep Learning, AutoML, modelos de fundación ni búsqueda de hiperparámetros, por lo que los resultados constituyen una línea base y no un análisis equivalente al de las series de BodegaAI. El SARIMA reutiliza la especificación de ALB y no fue ajustado a esta serie. Ridge y LightGBM reciben como variable exógena la marca de intervención del despliegue, que vale 1 entre el 17 y el 22 de septiembre aunque esta serie no fue afectada; con la marca en cero, el MASE de prueba de Ridge pasa de 0,784 a 0,756 y el de LightGBM no cambia, sin alterar el orden de los modelos ni el de validación. Ningún modelo requirió más de cuatro segundos de ajuste por ventana.

Por la regla de selección adoptada, el modelo seleccionado es la referencia estacional ingenua (MAE de validación de 21.146,77; MASE de 0,438), seguida por Prophet (0,655) y LightGBM

Tabla 8

Comparación de modelos – serie Wikipedia en español (MAE en visitas por hora; MASE adimensional).

Modelo	Familia	MAE val.	MASE val.	MAE prueba	MASE prueba
seasonal_naive_m24 (seleccionado)	Ingenuo	21.146,77	0,438	44.587,78	0,924
prophet_default	Prophet	31.597,99	0,655	54.035,34	1,119
lightgbm	ML	35.076,47	0,727	64.580,44	1,338
SARIMA (TP1 refit)	Fundacional TP1	49.383,80	1,023	121.296,69	2,513
holt_winters	Clásico	55.195,65	1,143	109.296,60	2,264
ridge	ML	65.234,87	1,351	37.830,60	0,784

(0,727). En el conjunto de prueba, en cambio, el mejor modelo es Ridge (MASE de 0,784), la referencia ingenua queda segunda (0,924) y el SARIMA del trabajo anterior es el peor (2,513; MAE de 121.296,69), precedido por Holt-Winters (2,264). La correlación de Spearman entre ambos ordenamientos, calculada sobre solo seis modelos, es de 0,09: el desacuerdo entre validación y prueba observado en las series de BodegaAI se repite aquí y, con una única ventana de cada tipo, no permite declarar un ganador firme.




Figura 11

Serie Wikipedia en español: MAE de prueba por modelo y pronóstico de los tres mejores sobre la ventana de prueba.

El contraste con las series de BodegaAI es el hallazgo principal de esta subsección: el SARIMA del trabajo anterior fue el modelo de mejor desempeño de prueba en ALB (MASE de 1,526) y es el de peor desempeño en Wikipedia. Holt-Winters y SARIMA, los dos modelos que solo utilizan un componente estacional de período 24, ocupan los últimos lugares, mientras que Ridge incorpora rezagos de hasta 336 horas y variables de calendario, y Prophet incluye por defecto un componente semanal. La autocorrelación semanal alta de la serie (Figura 11) es coherente con esa diferencia, pero este trabajo no la contrasta mediante un experimento, por lo que se presenta como una explicación plausible y no como un resultado verificado.

El pronóstico final de 48 horas se obtiene con el modelo seleccionado (la referencia estacional

ingenua) reajustado sobre la totalidad del historial, entre el 26 de septiembre de 2026 a las 23:00 UTC y el 28 de septiembre de 2026 a las 22:00 UTC (Figura 12). Al tratarse de la referencia ingenua, repite el perfil de las últimas 24 horas observadas y no distingue entre días de la semana; a diferencia de las series de BodegaAI, no se calcularon intervalos de predicción para esta serie.




Figura 12

Serie Wikipedia en español: últimos siete días observados y pronóstico final de 48 horas.

Conclusiones

Síntesis por serie

El objetivo planteado por la cátedra –determinar si los modelos contemporáneos de Machine Learning, Deep Learning, modelos híbridos, AutoML y modelos de fundación mejoran el pronóstico obtenido con el enfoque clásico del Trabajo Práctico N.º 1– admite una respuesta distinta según la serie y según el criterio utilizado. Para la serie ALB, el modelo seleccionado mediante la regla honesta de validación (AutoARIMA) mejora al SARIMA refit en un 48,5 % durante la validación, pero resulta un 34,9 % peor que ese mismo SARIMA en el conjunto de prueba; de las 32 configuraciones evaluadas, el propio SARIMA refit del trabajo anterior es, en definitiva, la de mejor desempeño de prueba. En esta serie, entonces, el enfoque clásico del trabajo anterior no fue superado por ningún modelo más reciente cuando se lo evalúa sobre datos no vistos durante el ajuste. Para la serie store-service, el modelo seleccionado (la referencia estacional ingenua) tampoco es superado en validación por ningún modelo no contaminado, pero en el conjunto de prueba sí lo supera un modelo de la familia Prophet (NeuralProphet, un 25,8 % mejor MASE que el modelo seleccionado), aunque ese modelo no habría sido elegido por la regla honesta de selección, dado su desempeño mediocre en validación (decimocuarto puesto de 32). La respuesta general, entonces, es matizada: los modelos más recientes pueden superar al enfoque clásico, pero no necesariamente lo hacen los mismos modelos que una regla de selección basada exclusivamente en validación elegiría.

Consistencia entre validación y prueba

La correlación de Spearman entre el orden de validación y el de prueba resultó baja y no significativa para ALB ($\rho = 0,237$, $p = 0,192$ sobre las 32 configuraciones) y moderada y significativa

para store-service ($\rho = 0,654$, $p < 0,001$). Esta diferencia entre series sugiere que la propia confiabilidad del protocolo de validación –y, por lo tanto, la confianza que puede depositarse en el modelo seleccionado– no es uniforme: para ALB, una ventana de validación de 48 horas ordena a los modelos de un modo que guarda poca relación con su desempeño posterior, mientras que para store-service ese orden es más informativo, aunque tampoco infalible, como lo demuestra el caso de NeuralProphet.

Serie pública de contraste

Sobre la serie de visitas horarias a Wikipedia en español, con seis modelos de hiperparámetros por defecto, la regla de selección por validación eligió la referencia estacional ingenua, mientras que en prueba el mejor modelo fue Ridge y el SARIMA del trabajo anterior el peor (2,513). El resultado es coherente con la conclusión general del trabajo: el desempeño relativo del enfoque clásico depende de la serie (fue el mejor en ALB y el peor en Wikipedia), y el orden de validación no anticipa el de prueba (Spearman de 0,09 sobre seis modelos). Por su alcance reducido, este resultado se interpreta como un contraste y no como una evaluación completa.

Límites del trabajo

1. **Ventana única de validación.** El protocolo utiliza una sola ventana de contraste de 48 horas, en lugar de una validación cruzada expandida de múltiples pliegues, debido al tiempo de cómputo que exige comparar 32 configuraciones por serie. Esta decisión probablemente explica, al menos en parte, la baja consistencia entre validación y prueba observada en ALB: una sola ventana de 48 horas es una muestra pequeña del comportamiento futuro de la serie y su resultado puede estar dominado por particularidades de esas horas específicas.
2. **Historial todavía acotado.** El historial efectivo disponible cubre 86 días (2.063 observaciones horarias), sensiblemente más que el mes del trabajo anterior, pero aún reducido para arquitecturas de Deep Learning con una cantidad considerable de parámetros, que pueden requerir un historial más extenso para generalizar de forma estable.
3. **Modelos con puntaje de validación contaminado.** Cinco de las 32 configuraciones por serie utilizan, para su propio ajuste de hiperparámetros o para la elección de sus miembros, la misma ventana de 48 horas luego utilizada para clasificarlas. Estos modelos se documentan y se muestran en las tablas y figuras de este informe, pero se excluyen de la selección; de haberse permitido, la regla habría seleccionado un modelo distinto en ambas series (Tabla 6), sin que ello implicara una mejora real en el conjunto de prueba.
4. **Posible anomalía en las últimas horas de store-service.** Las últimas horas registradas de la serie store-service (20:00 a 22:00 UTC del 26 de septiembre de 2026) muestran un patrón que se aparta del comportamiento de esas mismas horas en los cuatro días anteriores: una caída inusual a las 20:00 UTC, seguida de un valor por encima de lo esperado a las 21:00 UTC. No se identificó un patrón equivalente en la serie ALB durante esas mismas horas.

Esta observación no fue investigada en profundidad y no se descarta que corresponda a un artefacto puntual de exportación de datos más que a un cambio real del proceso subyacente; se documenta aquí como una limitación abierta y no como un hallazgo verificado.

5. **Estacionalidad semanal no aprovechada.** La estacionalidad semanal, débil pero no nula (fuerza de 0,206 en ALB y 0,311 en store-service según la descomposición MSTL), se excluyó de los modelos Prophet y NeuralProphet y del período estacional del MASE, sobre la base de un historial que, con 86 días, apenas cubre unas doce semanas completas; un historial más extenso podría justificar su incorporación.
6. **Serie pública con alcance acotado.** La serie de Wikipedia se evaluó con seis modelos de hiperparámetros por defecto, sin Deep Learning, AutoML ni modelos de fundación, con una única ventana de validación de 48 horas y una de prueba de 105 horas, y con un SARIMA cuya especificación proviene de ALB. Ridge y LightGBM reciben como variable exógena la marca de intervención del despliegue, que vale 1 entre el 17 y el 22 de septiembre aunque esta serie no fue afectada; con la marca en cero, el MASE de prueba de Ridge pasa de 0,784 a 0,756 y el de LightGBM no cambia, sin alterar el orden de los modelos ni el de validación. Sus resultados no son comparables uno a uno con los de las 32 configuraciones de las series de BodegaAI.

Líneas de trabajo futuro

La continuación más directa de este trabajo consiste en reemplazar la ventana única de validación por un esquema de validación cruzada de múltiples orígenes (*multi-origin validation*), en la línea de lo propuesto por Hyndman y Athanasopoulos (2021), que estime el error de generalización sobre varias ventanas sucesivas en lugar de una sola. Una segunda línea consiste en extender el historial disponible una vez que transcurra más tiempo desde la puesta en producción del sistema, lo que permitiría evaluar con mayor solidez tanto la estacionalidad semanal como la estabilidad de las arquitecturas de Deep Learning de mayor capacidad. Finalmente, la serie pública de Wikipedia se trató aquí solo como una línea base acotada; extenderle la batería completa (Deep Learning, AutoML, modelos de fundación y búsqueda de hiperparámetros) permitiría contrastar con mayor solidez si las conclusiones alcanzadas para las dos series de infraestructura de BodegaAI se sostienen en un dominio de datos distinto.

Declaración de uso de IA generativa

Siguiendo las recomendaciones de transparencia para citar y describir el uso de IA generativa en trabajos académicos (McAdoo et al., 2025), se declara que durante el desarrollo de este trabajo se emplearon agentes de IA generativa (Claude Code, de Anthropic, con el modelo Sonnet) como apoyo para la exploración del repositorio, el desarrollo y la revisión del código, y la redacción y edición del presente informe (Anthropic, 2026). El uso de estas herramientas tuvo carácter asistivo: las decisiones metodológicas, la selección de datos, la ejecución de los análisis, la validación de resultados y la responsabilidad final del informe corresponden a los autores.

Referencias bibliográficas

- Amat Rodrigo, J., & Escobar Ortiz, J. (2024). *skforecast: Forecasting time series with scikit-learn regressors*. Consultado el 28 de septiembre de 2026, desde <https://skforecast.org/>
- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Arango, S. P., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M., & Wang, Y. (2024). *Chronos: Learning the language of time series*. arXiv: 2403.07815. <https://arxiv.org/abs/2403.07815>
- Anthropic. (2026). Claude Code (Sonnet) [Agente de codificación con IA generativa]. <https://docs.anthropic.com/en/docs/claude-code/getting-started>
- Bai, S., Kolter, J. Z., & Koltun, V. (2018). *An empirical evaluation of generic convolutional and recurrent networks for sequence modeling*. arXiv: 1803.01271. <https://arxiv.org/abs/1803.01271>
- BodegaAI. (2026a). Registro horario de solicitudes atendidas por el balanceador de carga de producción (RequestCount), mayo–septiembre de 2026.
- BodegaAI. (2026b). Registro horario de solicitudes por destino del servicio de tienda (RequestCountPerTarget), mayo–septiembre de 2026.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th). Wiley.
- Box, G. E. P., & Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *Journal of the American Statistical Association*, 70(349), 70-79.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- Challu, C., Olivares, K. G., Oreshkin, B. N., Ramírez, F. G., Canseco, M. M., & Dubrawski, A. (2023). NHITS: Neural hierarchical interpolation for time series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(6), 6989-6997.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
- Das, A., Kong, W., Leach, A., Mathur, S., Sen, R., & Yu, R. (2023). *Long-term forecasting with TiDE: Time-series dense encoder*. arXiv: 2304.08424. <https://arxiv.org/abs/2304.08424>
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427-431.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232.
- Garza, F., Mergenthaler Canseco, M., Challú, C., & Olivares, K. G. (2022). *StatsForecast: Lightning fast forecasting with statistical and econometric models*. Nixtla. Consultado el 28 de septiembre de 2026, desde <https://github.com/Nixtla/statsforecast>
- Herzen, J., Lässig, F., Piazzetta, S. G., et al. (2022). *Darts: User-friendly modern machine learning for time series*. Consultado el 28 de septiembre de 2026, desde <https://github.com/unit8co/darts>

- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd). OTexts.
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.
- Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1-3), 159-178.
- Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748-1764.
- Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297-303.
- McAdoo, T., Denny, S., & Lee, C. (2025, 9 de septiembre). *Citing generative AI in APA Style: Part 1—Reference formats*. American Psychological Association. Consultado el 28 de septiembre de 2026, desde <https://apastyle.apa.org/blog/cite-generative-ai-references>
- Oreshkin, B. N., Carpov, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations (ICLR)*.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638-6648.
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92-96.
- Shchur, O., Turkmen, A. C., Erickson, N., Shen, H., Shirkov, A., Hu, T., & Wang, Y. (2023). AutoGluon-TimeSeries: AutoML for probabilistic time series forecasting. *International Conference on Automated Machine Learning (AutoML)*.
- Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37-45.
- Triebel, O., Hewamalage, H., Pilyugina, P., Laptev, N., Bergmeir, C., & Rajagopal, R. (2021). *NeuralProphet: Explainable forecasting at scale*. arXiv: 2111.15397. <https://arxiv.org/abs/2111.15397>
- Wikimedia Foundation. (2026). *Pageviews API: visitas horarias de usuarios a es.wikipedia* (aggregate, all-access, user), mayo-septiembre de 2026 [Datos publicados bajo dedicación CC0]. Consultado el 27 de septiembre de 2026, desde https://wikimedia.org/api/rest_v1/metrics/pageviews/
- Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241-259.

Apéndice A

Apéndice A. Tablas completas y material gráfico complementario

Las figuras y tablas de este apéndice documentan el análisis exploratorio y el conjunto completo de 32 configuraciones evaluadas por serie. Se excluyeron del cuerpo del informe por resultar redundantes respecto de las figuras allí incluidas, por referir a aspectos discutidos únicamente de forma numérica en el cuerpo, o por exceder el detalle necesario para sostener sus afirmaciones centrales.

Tabla A1

Conjunto completo de 32 configuraciones evaluadas – serie ALB.

Modelo	Familia	MAE val.	MASE val.	MAE prueba	MASE prueba	Contam.
naive	Ingenuo	140.474,23	3,548	103.514,69	2,615	No
seasonal_naive_m24	Ingenuo	19.369,02	0,489	78.784,34	1,990	No
drift	Ingenuo	143.670,97	3,629	102.288,71	2,584	No
average	Ingenuo	149.950,95	3,788	237.950,60	6,011	No
SARIMA (TP1 refit)	Fundacional TP1	36.524,57	0,923	60.429,07	1,526	No
holt_winters	Clásico	31.604,81	0,798	82.913,56	2,094	No
mstl_arima	Clásico	23.468,84	0,593	76.674,57	1,937	No
auto_arima	Clásico	18.807,50	0,475	81.488,75	2,058	No
lightgbm	ML	24.100,55	0,609	89.523,11	2,261	No
xgboost	ML	51.766,94	1,308	113.131,51	2,858	No
catboost	ML	23.676,28	0,598	92.090,22	2,326	No
random_forest	ML	24.013,59	0,607	89.523,51	2,261	No
ridge	ML	36.145,98	0,913	67.461,63	1,704	No
catboost_direct	ML (directo)	21.126,48	0,534	93.581,28	2,364	No
catboost_tuned	ML	13.994,36	0,353	91.577,78	2,313	Sí
random_forest_tuned	ML	16.478,21	0,416	136.787,15	3,455	Sí
lightgbm_tuned	ML	16.682,37	0,421	98.698,42	2,493	Sí
stacking_top3	ML	101.301,74	2,559	197.519,54	4,989	Sí
lstm	DL	75.584,94	1,909	309.470,41	7,817	No
nbeats	DL	38.805,46	0,980	69.030,03	1,744	No
nhits	DL	22.021,71	0,556	96.620,17	2,441	No
tcn	DL	45.631,83	1,153	132.828,03	3,355	No
tft	DL	60.751,26	1,535	109.629,69	2,769	No
tide	DL	31.271,07	0,790	70.489,78	1,781	No
prophet_default	Prophet	21.066,96	0,532	81.749,90	2,065	No
prophet_tuned	Prophet	26.085,28	0,659	62.468,36	1,578	No
neuralprophet	Prophet	29.444,69	0,744	72.996,75	1,844	No
mstl_lightgbm	Híbrido	28.341,14	0,716	226.471,23	5,721	No
autogluon_timeseries	AutoML	19.748,53	0,499	78.152,68	1,974	No
autots	AutoML	29.913,83	0,756	77.200,09	1,950	No
chronos_bolt_base	Fundación	23.678,74	0,598	79.453,52	2,007	No
ensemble_equal_weight	Ensamble	16.006,29	0,404	93.116,04	2,352	Sí

Tabla A2

Conjunto completo de 32 configuraciones evaluadas – serie store-service.

Modelo	Familia	MAE val.	MASE val.	MAE prueba	MASE prueba	Contam.
naive	Ingenuo	16.585,83	3,490	12.080,82	2,542	No
seasonal_naive_m24	Ingenuo	2.281,85	0,480	6.858,35	1,443	No
drift	Ingenuo	17.022,66	3,582	12.292,99	2,587	No
average	Ingenuo	11.991,26	2,523	11.365,28	2,392	No
SARIMA (TP1 refit)	Fundacional TP1	3.075,43	0,647	6.775,50	1,426	No
holt_winters	Clásico	6.840,69	1,439	7.910,62	1,665	No
mstl_arima	Clásico	3.116,58	0,656	6.738,21	1,418	No
auto_arima	Clásico	2.525,88	0,532	6.693,19	1,408	No
lightgbm	ML	6.763,12	1,423	7.134,86	1,501	No
xgboost	ML	6.958,01	1,464	7.781,26	1,637	No
catboost	ML	8.076,39	1,700	9.427,28	1,984	No
random_forest	ML	8.057,11	1,695	6.644,16	1,398	No
ridge	ML	5.709,70	1,201	10.402,06	2,189	No

Tabla A2 (continuación)

Modelo	Familia	MAE val.	MASE val.	MAE prueba	MASE prueba	Contam.
ridge_direct	ML (directo)	2.905,15	0,611	8.742,22	1,840	No
ridge_tuned	ML	5.707,42	1,201	10.342,18	2,176	Sí
lightgbm_tuned	ML	2.723,67	0,573	8.411,54	1,770	Sí
xgboost_tuned	ML	3.281,09	0,690	6.723,50	1,415	Sí
stacking_top3	ML	9.327,31	1,963	9.412,96	1,981	Sí
lstm	DL	3.458,53	0,728	7.928,91	1,668	No
nbeats	DL	3.031,39	0,638	5.927,84	1,247	No
nhits	DL	3.276,37	0,689	7.119,14	1,498	No
tcn	DL	3.476,89	0,732	7.223,69	1,520	No
tft	DL	5.147,35	1,083	9.260,54	1,949	No
tide	DL	4.094,99	0,862	7.909,85	1,664	No
prophet_default	Prophet	2.405,88	0,506	5.145,67	1,083	No
prophet_tuned	Prophet	2.432,33	0,512	5.439,47	1,145	No
neuralprophet	Prophet	3.297,54	0,694	5.090,39	1,071	No
mstl_lightgbm	Híbrido	8.779,73	1,848	14.729,52	3,100	No
autoglun_timeseries	AutoML	3.808,36	0,801	8.677,17	1,826	No
autots	AutoML	2.412,97	0,508	7.582,50	1,596	No
chronos_bolt_base	Fundación	3.877,73	0,816	7.949,65	1,673	No
ensemble_equal_weight	Ensamble	2.281,64	0,480	7.661,02	1,612	Sí




Figura A1

Descomposición MSTL (tendencia, estacionalidad diaria y semanal, residuo), serie ALB.

Apéndice B

Apéndice B. Rutinas de cómputo

Este apéndice reproduce, en forma completa, dos rutinas centrales del protocolo cuyo frag-mento se citó de forma abreviada en el cuerpo del informe: la imputación de la intervención de




Figura A2

Descomposición MSTL, serie store-service.




Figura A3

Perfil horario por día de la semana (mapa de calor), serie ALB.




Figura A4

Perfil horario por día de la semana (mapa de calor), serie store-service.





Figura A5

Autocorrelación y autocorrelación parcial, serie ALB.


despliegue y el cálculo del conjunto de flags de contaminación utilizado por la regla de selección.

```
def impute_intervention(series: pd.Series, start: pd.Timestamp, end: pd.Timestamp) ->
    pd.Series:
    """Reemplaza [start, end] por el valor de t-168h, corregido por la razon
    entre el nivel de la semana previa a la intervencion y el de la semana
    anterior a esa. Preserva el crecimiento organico semana a semana en lugar
    de asumir que el nivel pre-intervencion se repite sin cambios."""
    pre_window = series.loc[start - pd.Timedelta(hours=168):start - pd.Timedelta(
        hours=1)]
    prior_week = series.loc[start - pd.Timedelta(hours=336):start - pd.Timedelta(
        hours=169)]
    ratio = pre_window.mean() / prior_week.mean()

    imputed = series.copy()
    mask = (series.index >= start) & (series.index <= end)
```

**Figura A6**

Autocorrelación y autocorrelación parcial, serie store-service.

**Figura A7**

Correlación cruzada entre ALB y store-service (serie transformada), rezagos de -24 a 24 horas.

```
imputed.loc[mask] = series.shift(168).loc[mask] * ratio
return imputed
```

Código 3: Imputación de la ventana de intervención mediante el valor de la semana anterior corregido por nivel (tsa_final/data.py).

```
CONTAMINATED_MODELS = {
    "catboost_tuned": _TUNED_REASON,
    "random_forest_tuned": _TUNED_REASON,
    "lightgbm_tuned": _TUNED_REASON,
    "ridge_tuned": _TUNED_REASON,
    "xgboost_tuned": _TUNED_REASON,
    "stacking_top3": _STACKING_REASON,
    "ensemble_equal_weight": _ENSEMBLE_REASON,
```




Figura A8

Importancia de variables (SHAP) del mejor modelo de Machine Learning, serie store-service.




Figura A9

MASE de validación, modelos de Machine Learning (fase 03), ambas series.




Figura A10

MAPE de validación, referencias ingenuas y modelos clásicos (fase 02), ambas series.




Figura A11

Pronóstico de prueba de los mejores modelos de la fase 02, ambas series.




Figura A12

Pronóstico de prueba del mejor modelo de la fase 05 (Prophet, híbridos, AutoML y fundación), ambas series.

```
# prophet_tuned se ajusta sobre una ventana segura de 168h, no sobre la
# ventana de validacion: no se marca como contaminado.
}

def add_contamination_flags(pool: pd.DataFrame) -> pd.DataFrame:
    pool = pool.copy()
    pool["val_contaminated"] = pool["model"].isin(CONTAMINATED_MODELS)
    pool["contamination_reason"] = pool["model"].map(CONTAMINATED_MODELS).fillna("")
    return pool

def eligible_val(pool: pd.DataFrame, series: str) -> pd.DataFrame:
    """Modelos elegibles para seleccion: split == 'val' y no contaminados,
    ordenados por MAE de validacion ascendente."""
    mask = (pool["series"] == series) & (pool["split"] == "val") & (~pool["
        val_contaminated"])
    return pool.loc[mask].sort_values("MAE")
```

Código 4: Marcado de modelos con puntaje de validación contaminado (tsa_final/selection.py).

Serie pública (Wikipedia en español): métricas completas

La Tabla B1 reúne las métricas de los seis modelos evaluados sobre la serie de Wikipedia en español (MAE y RMSE en visitas por hora; MAPE en porcentaje; MASE adimensional; tiempo de ajuste sumado de ambas ventanas, en segundos), ordenados por MAE de validación.

Tabla B1

Métricas completas de los seis modelos – serie Wikipedia en español.

Modelo	Familia	MAE val.	RMSE val.	MAPE val.	MASE val.	MAE prueba	RMSE prueba	MAPE prueba	MASE prue
seasonal_naive_m24	Ingenuo	21.146,77	28.220,67	3,52	0,438	44.587,78	80.143,84	7,83	0,9
prophet_default	Prophet	31.597,99	42.467,81	4,75	0,655	54.035,34	65.758,18	8,40	1,1
lightgbm	ML	35.076,47	44.188,30	5,57	0,727	64.580,44	73.268,00	10,65	1,3
SARIMA (TP1 refit)	Fundacional TP1	49.383,80	58.360,80	8,72	1,023	121.296,69	128.588,33	20,11	2,5
holt_winters	Clásico	55.195,65	63.954,68	9,53	1,143	109.296,60	114.055,16	17,73	2,2
ridge	ML	65.234,87	73.356,31	10,56	1,351	37.830,60	44.596,89	6,48	0,7